

RAPPRESENTAZIONE IN "FLOATING POINT" → VIRGOLA MOBILE

• RISULTA UTILE USARE LA NOTAZIONE SCIENTIFICA → $1.5 \cdot 10^6$

• UN NUMERO REALE PUÒ ESSERE MEMORIZZATO CON UNA PAROLA CON 3 CAMPI:

- SEGNO ($\pm$)
- MANTISSA (S), ANCHE DETTA "SIGNIFICAND"
- ESPONENTE (E)

32 bit	ESPONENTE (E)	MANTISSA (S)
--------	---------------	--------------

• IL NUMERO VIENE NORMALIZZATO NELLA FORMA $1.bbb \dots b \cdot 2^E$

- IL VALORE "1" IN EVIDENZA È IL PRIMO BIT DIVERSO DA ZERO DEL NUMERO ESPRESSO IN VIRGOLA FISSA
- POICHÉ QUESTO "1" È SEMPRE PRESENTE LO SI CONSIDERA "IMPLICITO", E SI MEMORIZZANO SOLO I BIT SUCCESSIVI

• L'ESPONENTE È SCALATO RISPETTO AD UN VALORE COSTANTE DETTO "POLARIZZAZIONE" O "ECESSO"

- IN GENERALE È PARI A $2^{K-1} - 1$, DOVE K È IL NUMERO DI BIT DEL CAMPO ESPONENTE
- L'INTERVALLO DI BASE DELL'ESPONENTE È $0 - (2^{K-1} - 1)$
- SI SOMMA LA POLARIZZAZIONE ALL'ESPONENTE PER OTTENERE IL VALORE REALE DEL CAMPO ESPONENTE
- CONSIDERANDO QUESTA POLARIZZAZIONE, L'INTERVALLO DELL'ESPONENTE DIVENTA $-(2^{K-1} - 1) - (2^{K-1})$

ESEMPIO DI NUMERO IN "FLOATING POINT"


• ESPRIMERE IN FLOATING POINT IL NUMERO $(53)_{10}$ SAPEANDO CHE: LA MANTISSA È DI 8 BIT
→ L'ESPONENTE È DI 4 BIT, RAPPRESENTATO IN ECESSO 7

• CONVERSIONE DECIMALE-BINARIO → $(53)_{10} = (110101)_2$

• NORMALIZZAZIONE DELLA MANTISSA $110101 \rightarrow 1.10101 \cdot 2^5$


• RAPPRESENTAZIONE DELL'ESPONENTE IN ECESSO 7: $5 + 7 = 12 \rightarrow 1011111 = 1100$

• IL BIT IMPLICITO SI OMETTE IN QUANTO LA NORMALIZZAZIONE ADOTTATA LO SOTTINTENDE
 $1100 = 12$ IL BIAS PER L'ESPONENTE SÌ 7 (STANDARD PER 4 BIT $2^{4-1} - 1 = 7$) $12 - 7 = 5$




S 8 BIT DI SEGNO
E 4 BIT
M 7/8 BIT

IEEE 754



- È lo standard per la rappresentazione dei numeri in floating point.
- Sono previsti due formati: 32 e 64 bit.
- L'esponente ha 8 e 11 bit rispettivamente.
- La mantissa ha 23 e 52 bit rispettivamente.
- Esistono anche dei formati estesi (sia per mantissa che per esponente) che sono usati per i calcoli intermedi



• NON VI È UNA RAPPRESENTAZIONE DELLO ZERO
SI USA UNA PARTICOLARE CONFIGURAZIONE PER RAPPRESENTARE LO ZERO: BIT E E BIT M TUTTI A ZERO

Caratteristiche del IEEE 754 a 32 bit	
• Esponente rappresentato in eccesso 127	• Mantissa frazionaria e normalizzata con bit implicito (1.M)
11111111 128	• Es.
...	→ $(51)_{10} = 1.10011 \cdot 2^5$
10000000 1	• Mantissa: 10011
01111111 0	• Esponente:
...	→ $5 + 101 + 01111111 = 1000100$
00000000 -127	

Densità dei numeri in floating point

- I numeri rappresentabili non sono equispaziati.
 - La "densità" maggiore di valori rappresentabili si ha vicino all'origine.
- Un valore reale compreso tra due valori rappresentabili viene approssimato al più vicino nell'approssimazione.
 - Laddove vi è "scarsa densità" abbiamo minore precisione.
- C'è un legame tra numero di bit, intervallo di valori e precisione.
 - A parità di numero di bit complessivi, aumentando l'intervallo di valori rappresentabili (riducendo i numeri di bit della mantissa a favore dell'esponente), diminuisce la precisione.
 - A parità di intervallo (numero di bit per l'esponente), aumentando il numero di bit complessivi aumenta la precisione.
 - Singola e doppia precisione.

ESEMPIO

- Sono dati i seguenti rappresentazione dei numeri (campo complessivo 48 bit): formati in un per la calcolatore
 - Interi senza segno
 - Reali in virgola fissa con bit di segno, parte intera e 16 bit per la parte frazionaria
 - Reali in virgola mobile con bit di segno, esponente in eccesso 63 (7 bit) e mantissa frazionaria enormalizzata in segno e valore 1.M
- Si richiede il minimo e massimo valore positivi, escluso lo zero

• INTERI SENZA SEGNO → MINIMO = 0, MASSIMO = $2^N - 1 = 2^8 - 1 = 255$

• REALI IN VIRGOLA FISSA CON BIT DI SEGNO, PARTE INTERA E 16 BIT PER LA PARTE FRAZIONARIA → MINIMO = 2^{-16} , MASSIMO = $2^8 - 2^{-16}$

• REALI IN VIRGOLA MOBILE CON BIT DI SEGNO, ESPONENTI IN ECESSO 63 (7 BIT) E MANTISSA FRAZIONARIA E NORMALIZZATA IN SEGNO E VALORE 1.M → MINIMO = 2^{-64} , MASSIMO = $2^{63} - 2^{-64}$

Aritmetica in floating point

- Per addizione/sottrazione si eseguono i seguenti 4 passi:
 - Si controlla se uno dei due operandi è nullo.
 - Si allineano le mantisse (aggiustando gli esponenti).
 - Si esegue l'addizione o la sottrazione delle mantisse.
 - Si normalizza il risultato.
- Moltiplicazione/Divisione sono più semplici

	S	E	M
A	0	1100	110101000
B	0	1011	111001100

L'ESPONENTE DI A È MAGGIORE DI QUELLO DI B, È NECESSARIO ALLINEARE B RISPETTO AD A, E POI SOMMARE LE MANTISSE, SENZA SCORDARSI DEL BIT IMPLICITO DELLE RISPETTIVE MANTISSE

A	0	1100	110101000	+
B	0	1100	011100110	
Somma	0	1100	101000110	
↓				
Somma	0	1101	101000111	

POICHÉ IL RISPETTO FINALE (IN GRIGIO) È DIVERSO DA ZERO, È NECESSARIO INCREMENTARE

L'ESPONENTE PER NORMALIZZARE LA MANTISSA

Floating Point Numbers	Arithmetic Operations
$X = X_s \times B^{E_x}$ $Y = Y_s \times B^{E_y}$	$X + Y = (X_s \times B^{E_x} + Y_s \times B^{E_y}) \times B^{E_x}$ $X - Y = (X_s \times B^{E_x} - Y_s \times B^{E_y}) \times B^{E_x}$ $X \times Y = (X_s \times Y_s) \times B^{E_x + E_y}$ $\frac{X}{Y} = \left(\frac{X_s}{Y_s} \right) \times B^{E_x - E_y}$

