Appunti di Cloud Networking

AWS Storage and Database Services

Obiettivo degli appunti

Questi appunti spiegano i principali servizi AWS di storage e database trattati nel PDF: Amazon S3, S3 Glacier, Amazon EFS, Amazon Aurora, Amazon DynamoDB e Amazon Redshift. L'obiettivo e capire quando usare ogni servizio, quali problemi risolve e quali differenze sono importanti per l'esame.

Indice rapido

- 1. Amazon S3: object storage gestito
- 2. Classi di storage S3 e lifecycle policies
- 3. Bucket, URL, ridondanza, scenari comuni e pricing
- 4. Amazon S3 Glacier: archiviazione a basso costo
- 5. Amazon EFS: file system condiviso e scalabile
- 6. Amazon Aurora: database relazionale gestito
- 7. DynamoDB: database NoSQL key-value/document
- 8. Amazon Redshift: data warehouse analitico
- 9. Tabelle di confronto
- 10. Glossario e domande d'esame con risposta

1. Amazon S3: object storage gestito

- **Amazon Simple Storage Service**, cioe Amazon S3, e un servizio gestito di object-level storage: non ragiona come un disco a blocchi, ma come un contenitore di oggetti.
- In S3 i file vengono chiamati oggetti. Gli oggetti vengono memorizzati dentro bucket, cioe contenitori logici creati in una specifica AWS Region.
- Per modificare anche solo una piccola parte di un file, in un modello object storage bisogna ricaricare l'intero file aggiornato. Questo lo distingue dallo storage a blocchi, dove si puo modificare solo il blocco interessato.
- S3 consente uno storage praticamente illimitato: un bucket puo contenere un numero illimitato di oggetti e ogni oggetto puo arrivare fino a 5 TB.
- Il nome del bucket deve essere universalmente unico in tutto Amazon S3, non solo dentro il singolo account.
- Per impostazione predefinita i dati in S3 sono memorizzati in modo ridondante su piu strutture e piu dispositivi dentro la Region selezionata.

Idea chiave da ricordare

S3 non e un disco collegato a EC2: e object storage gestito. Si usa quando devo archiviare oggetti, backup, contenuti statici, dati multimediali, file applicativi o dataset, non quando mi serve un volume di boot o un file system montato come disco tradizionale.

2. Classi di storage S3 e lifecycle policies

- Amazon S3 offre diverse classi di storage per adattare costo, disponibilita, accesso e tempi di recupero al tipo di dato.
- Le classi per dati attivi sono pensate per oggetti ancora usati dalle applicazioni. Le classi per archivio sono pensate per conservazione a lungo termine e accessi rari.

Classe S3	Tipo di dati	Quando usarla	Nota importante

S3 Standard	Dati acceduti frequentemente	Applicazioni, contenuti, oggetti usati spesso	Alta durabilita, disponibilita e performance
S3 Intelligent-Tiering	Accesso variabile o imprevedibile	Quando non si sa quanto spesso i dati saranno letti	Sposta automaticamente gli oggetti fra tier in base ai pattern di accesso
S3 Standard-IA	Dati acceduti raramente ma da recuperare rapidamente	Backup, disaster recovery, long-term storage con accesso rapido	Costo storage piu basso ma costo di retrieval
S3 One Zone-IA	Dati ricreabili o copie secondarie	Backup secondari o dati non critici	Costo minore, ma dati in una sola Availability Zone
S3 Glacier	Archiviazione	Dati da conservare a basso costo	Recupero da minuti a ore
S3 Glacier Deep Archive	Archivio a lunghissimo termine	Compliance, retention 7-10 anni o piu, accesso molto raro	Costo piu basso, restore entro circa 12 ore

- Le lifecycle policies permettono di eliminare o spostare automaticamente oggetti in base alla loro eta. Le regole possono essere definite a livello di bucket.
- Esempio del PDF: un file Preview2.mp4 parte da S3 Standard, dopo 30 giorni passa a S3 Standard-IA, dopo altri 60 giorni passa a S3 Glacier e dopo 365 giorni viene eliminato.

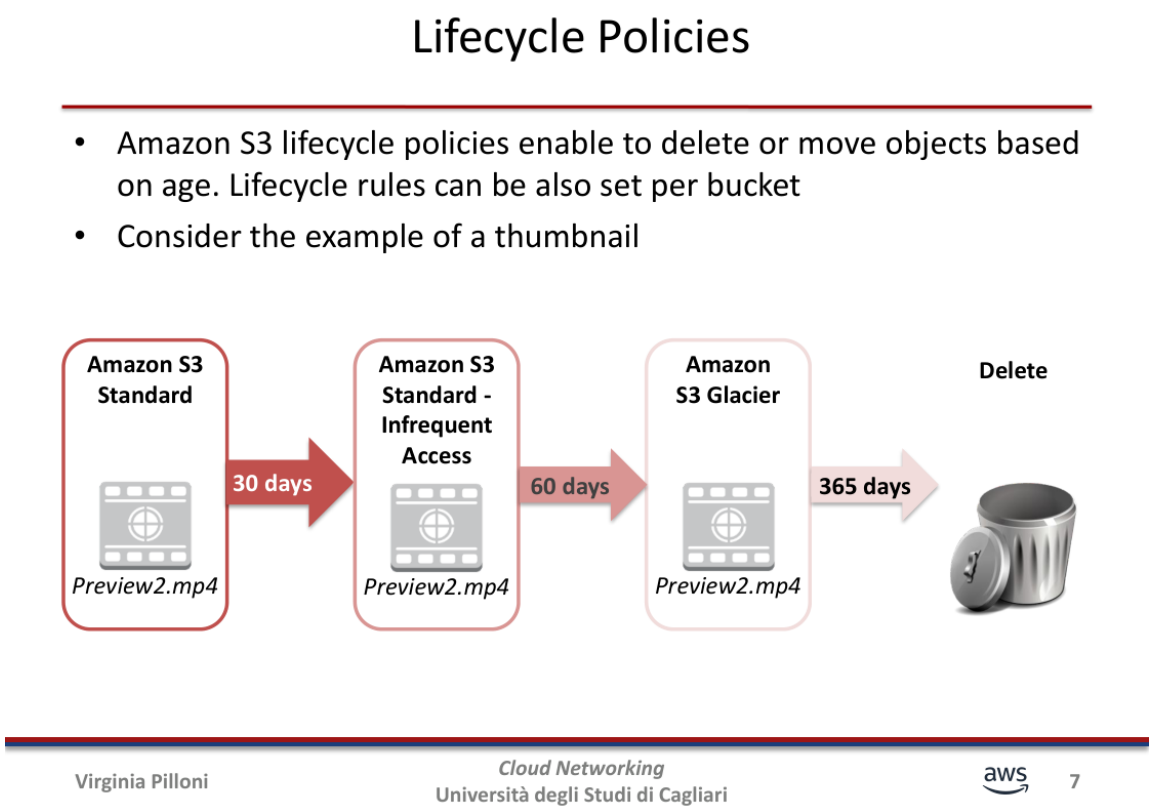


Figura - slide 7: esempio di lifecycle policy con transizione Standard, Standard-IA, Glacier e delete

3. Bucket, URL, ridondanza, scenari comuni e pricing

- Un bucket e il contenitore logico in cui vengono caricati gli oggetti. Per usare S3 si crea un bucket in una Region e poi si caricano gli oggetti.
- Un bucket puo essere raggiunto tramite endpoint URL. Il PDF mostra due forme: path-style e virtual hosted-style.
- Nel path-style endpoint il nome del bucket compare dopo il dominio della Region; nel virtual hosted-style endpoint il nome del bucket e parte del nome host.

Amazon S3 Bucket URLs



Buckets are logical containers for objects

To upload your data:

1. Create a **bucket** in an AWS Region
2. Upload almost any number of **objects** to the bucket

Bucket path-style URL endpoint:

https://s3.ap-northeast-1.amazonaws.com/bucket-name

Region code **Bucket name**

Bucket virtual hosted-style URL endpoint:

https:// bucket-name.s3-ap-northeast-1.amazonaws.com

Bucket name **Region code**

Figura - slide 8: forme principali degli URL dei bucket S3

- Quando un oggetto viene salvato in un bucket, S3 lo memorizza ridondantemente su piu facility nella Region selezionata. Questo aumenta durabilita e disponibilita del dato.

Data Is Redundantly Stored In the Region

- When data is stored in the bucket, it is redundantly stored across multiple AWS facilities within the selected Region

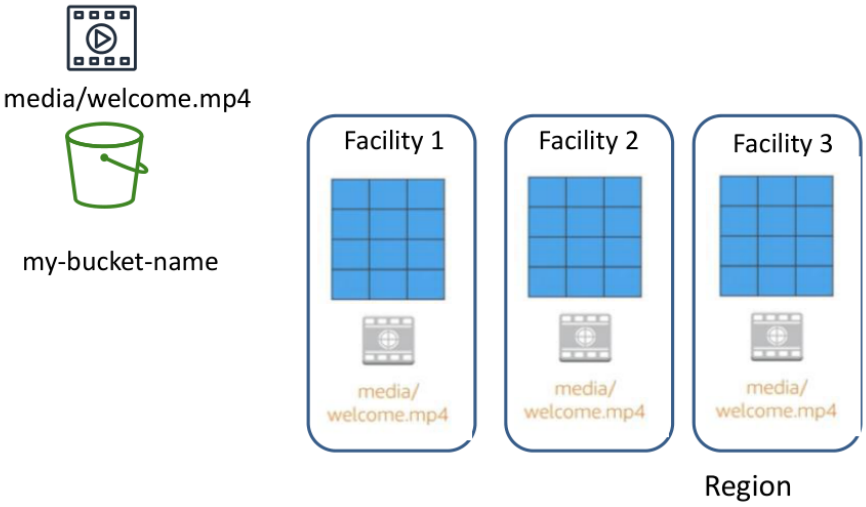


Figura - slide 9: memorizzazione ridondante dei dati dentro la Region

- Gli scenari comuni includono backup and storage, application hosting, media hosting e software delivery.

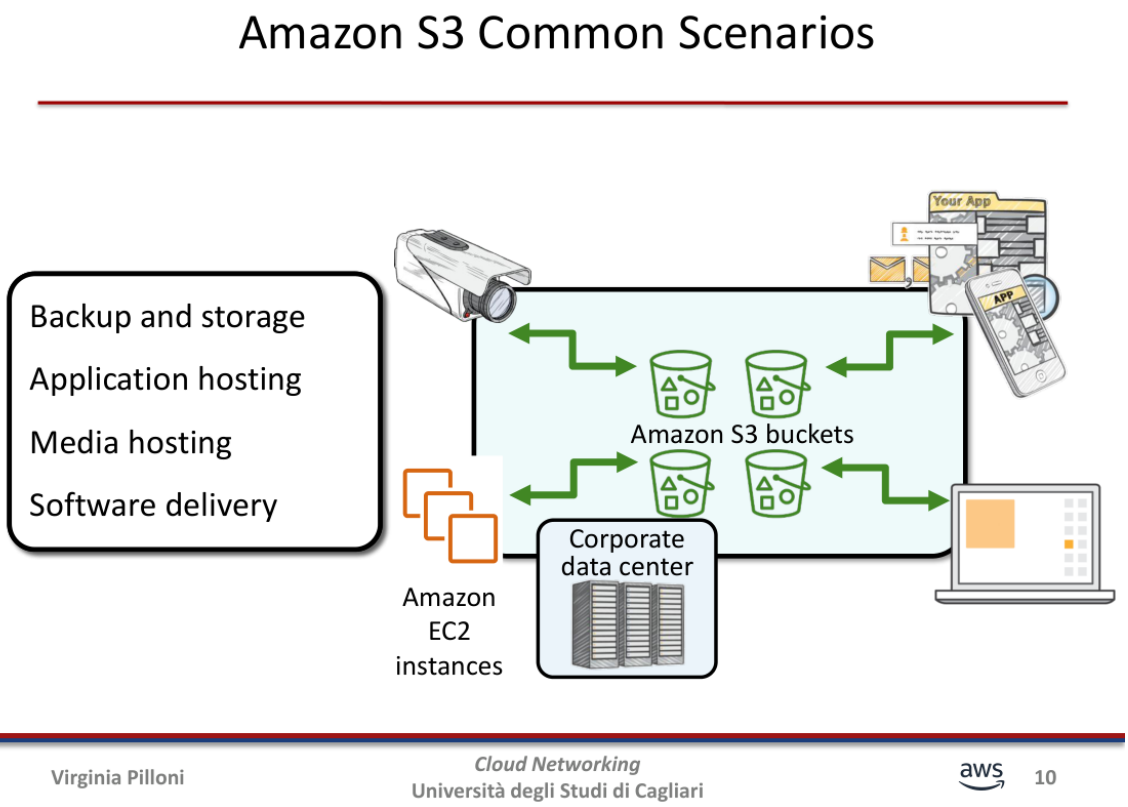


Figura - slide 10: scenari comuni di utilizzo di Amazon S3

- Il costo di S3 dipende da classe di storage, quantita di storage, numero e tipo di richieste e trasferimento dati in uscita dalla Region.
- Si paga per GB/mese, richieste PUT/COPY/POST/LIST/GET e trasferimenti OUT. Non si paga il trasferimento IN verso S3, ne il trasferimento OUT da S3 verso CloudFront o EC2 nella stessa Region.

4. Amazon S3 Glacier: archiviazione a basso costo

- Amazon S3 Glacier e un servizio di archiviazione progettato per sicurezza, durabilita e costo molto basso.
- Non e pensato per dati da leggere continuamente: il recupero puo richiedere da pochi minuti a diverse ore, in base al tipo di retrieval scelto.
- Gli elementi principali sono archive, vault e vault access policy.

Elemento		Significato	
Archive		Oggetto archiviato, ad esempio foto, video, file o documento. E l'unita base di storage in S3 Glacier e ha un ID univoco.	
Vault		Contenitore in cui vengono salvati gli archive. Quando si crea un vault si specificano nome e Region.	
Vault access policy		Policy che definisce chi puo accedere ai dati e quali operazioni puo eseguire. Le vault lock policies impediscono modifiche non autorizzate alla configurazione.	
Opzione di retrieval	**Tempo tipico**	**Costo relativo**	**Uso**
Expedited	1-5 minuti	Piu alto	Quando serve recuperare rapidamente dati archiviati
Standard	3-5 ore	Intermedio	Recupero ordinario di archivi
Bulk	5-12 ore	Piu basso	Recuperi massivi non urgenti

- La console AWS permette solo alcune operazioni su Glacier, come creare/eliminare vault e gestire policy. Gli strumenti piu usati sono REST API, SDK Java/.NET e AWS CLI.
- E possibile usare lifecycle policies di S3 per spostare automaticamente dati verso Glacier.

Aspetto	Amazon S3	Amazon S3 Glacier
Volume dati	Nessun limite	Nessun limite
Latenza media	Millisecondi	Minuti/ore

Dimensione item	Fino a 5 TB	Fino a 40 TB
Costo per GB/mese	Piu alto	Piu basso
Richieste fatturate	PUT, COPY, POST, LIST, GET	UPLOAD e retrieval
Retrieval pricing	Per richiesta	Per richiesta e per GB

- Dal punto di vista sicurezza, l'accesso viene controllato con IAM; S3 Glacier cifra i dati con AES-256 e gestisce le chiavi per l'utente.



Figura - slide 18: controllo accessi e cifratura in Amazon S3 Glacier

5. Amazon EFS: file system condiviso e scalabile

- Amazon Elastic File System, cioe Amazon EFS, e un servizio completamente gestito per creare file storage scalabile in AWS.
- Supporta Network File System versioni 4.0 e 4.1 ed e compatibile con le AMI Linux-based per Amazon EC2.
- Si usa per big data e analytics, media processing workflows, content management, web serving e home directories.
- Le caratteristiche principali sono petabyte-scale, bassa latenza, storage condiviso ed elastic capacity.

Differenza pratica EFS/S3/EBS

EFS e file storage condiviso montabile da piu istanze. S3 e object storage per oggetti in bucket. EBS e block storage persistente collegato a EC2. Se devo condividere un file system tra istanze Linux, EFS e spesso il servizio piu adatto.

- L'architettura EFS usa mount target nelle subnet appropriate. Le istanze EC2 si collegano ai mount target per accedere al file system.

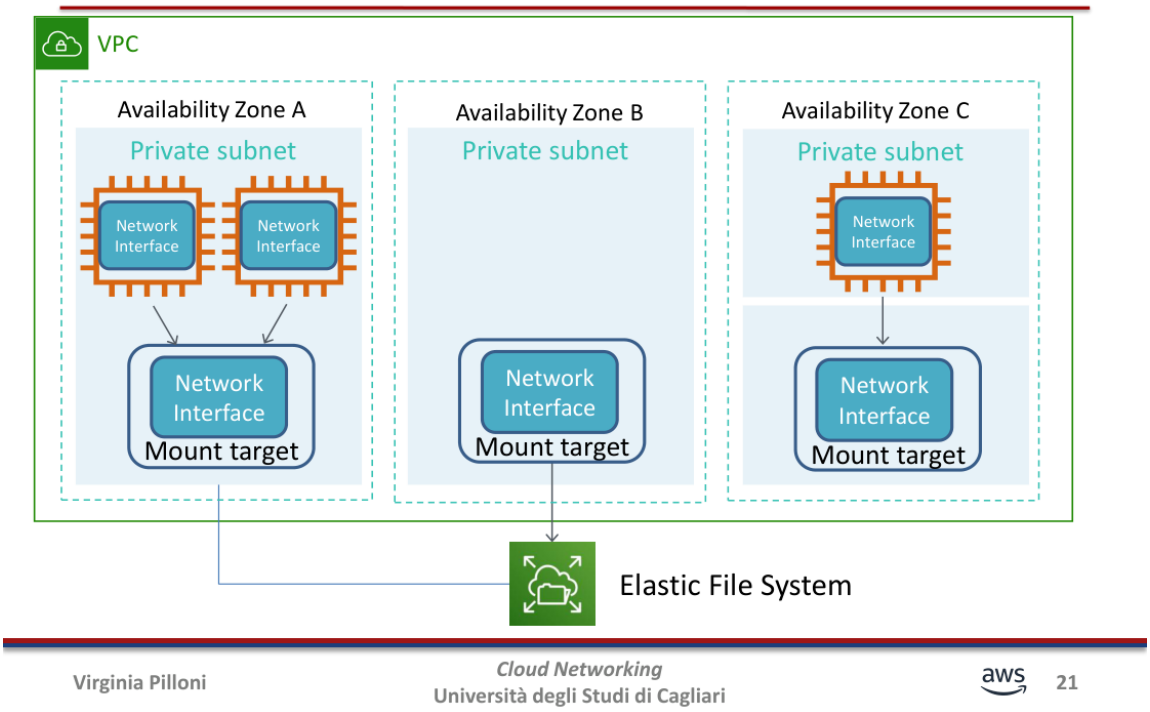


Figura - slide 21: architettura di Amazon EFS con mount target nelle Availability Zones

- Implementazione tipica: creare le risorse EC2, creare il file system EFS, creare i mount target nelle subnet, collegare le istanze EC2 ai mount target e verificare sicurezza e protezione dell'account.
- La risorsa primaria e il file system. Risorse collegate sono i mount target, i tag e le proprieta del file system come ID, creation token, creation time, size, numero di mount target e stato.

6. Amazon Aurora: database relazionale gestito

- Amazon Aurora e un database relazionale completamente gestito compatibile con MySQL e PostgreSQL.
- Combina performance e disponibilita tipiche dei database commerciali con semplicita e costo dei database open-source.
- Automatizza operazioni onerose come provisioning, patching, backup, recovery, failure detection e repair.

Amazon Aurora

- Amazon Aurora is a fully managed MySQL- and PostgreSQL-compatible relational database
  - It combines the performance and availability of high-end commercial databases with the simplicity and cost-effectiveness of open-source databases
  - It can reduce database costs while improving the reliability and availability of the database



Amazon Aurora

- Enterprise-class relational database
- Compatible with MySQL or PostgreSQL
- Automate time-consuming tasks (such as provisioning, patching, backup, recovery, failure detection, and repair)

Figura - slide 25: panoramica di Amazon Aurora

- I benefici principali indicati nel PDF sono: managed service, pay-as-you-go, fast and available, simple e compatible.
- Aurora e progettato per alta disponibilita: conserva piu copie dei dati su piu Availability Zones e usa backup continui verso Amazon S3.
- Puo usare fino a 15 read replica per ridurre il rischio di perdita dati e migliorare la scalabilita delle letture.
- Se il database primario diventa unhealthy, Aurora e progettato per instant crash recovery.

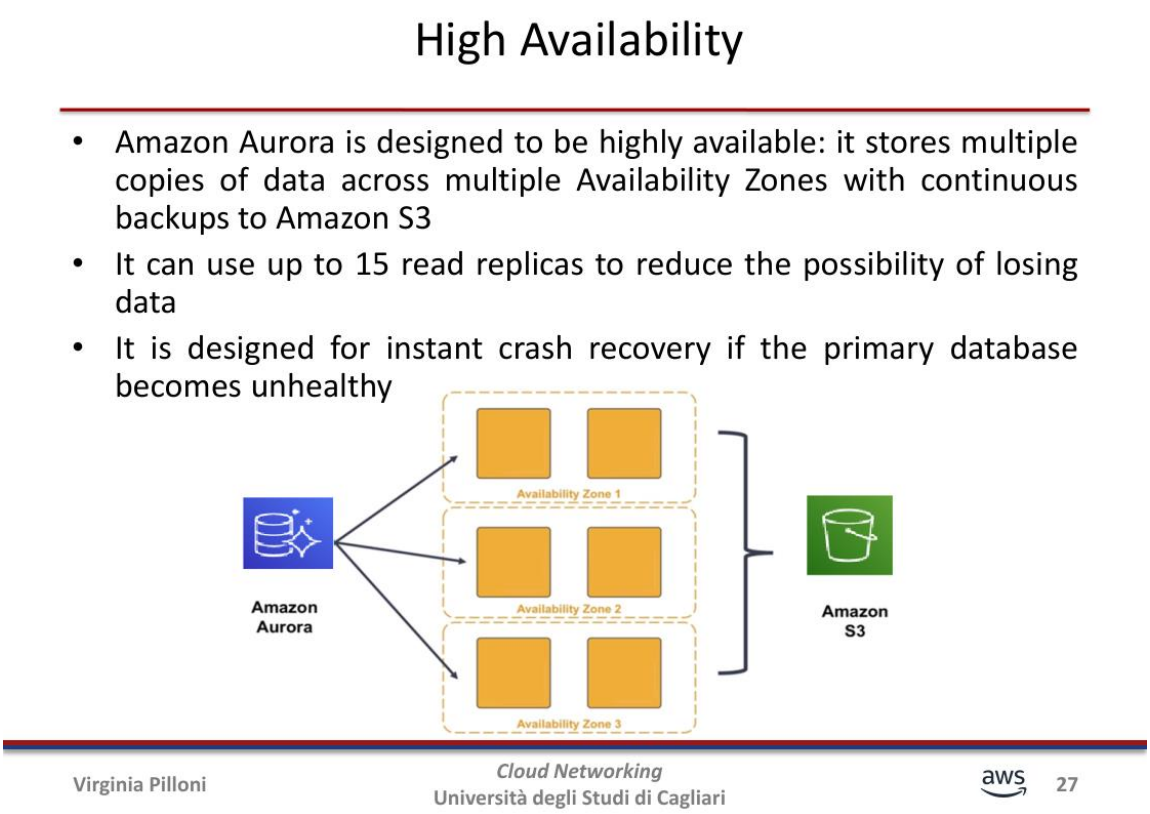


Figura - slide 27: alta disponibilita Aurora con copie dei dati su piu Availability Zones e backup su S3

7. Amazon DynamoDB: database NoSQL key-value/document

- Prima di capire DynamoDB bisogna distinguere database relazionali e non relazionali.
- Un database relazionale lavora con dati strutturati organizzati in tabelle, record e colonne. Usa SQL e relazioni ben definite tra tabelle.
- Un database non relazionale non segue il modello relazionale classico. E adatto a dati semi-strutturati o non strutturati e scala orizzontalmente.

Aspetto	Relazionale / SQL	Non relazionale / NoSQL
Data storage	Righe e colonne	Key-value, document, graph
Schema	Fisso	Dinamico
Querying	SQL	Accesso orientato a documenti/collezioni
Scalabilita	Verticale	Orizzontale
Quando conviene	Dati molto strutturati e relazioni forti	Dati flessibili, grandi volumi, accessi rapidi e scalabilita

- Amazon DynamoDB e un servizio NoSQL veloce e flessibile, pensato per qualunque scala.
- Offre tabelle NoSQL, storage virtualmente illimitato, item con attributi diversi, query a bassa latenza e throughput di lettura/scrittura scalabile.
- I componenti core sono table, item e attributes: una table e una collezione di dati; un item e un gruppo di attributi identificabile; un attribute e un elemento dati fondamentale.

Amazon DynamoDB Core Components

- Tables, items, and attributes are the core DynamoDB components
  - **Attributes** are a fundamental data element, something that does not need to be broken down any further
  - **Items** are a group of attributes that is uniquely identifiable among all other items
  - A **table** is a collection of data

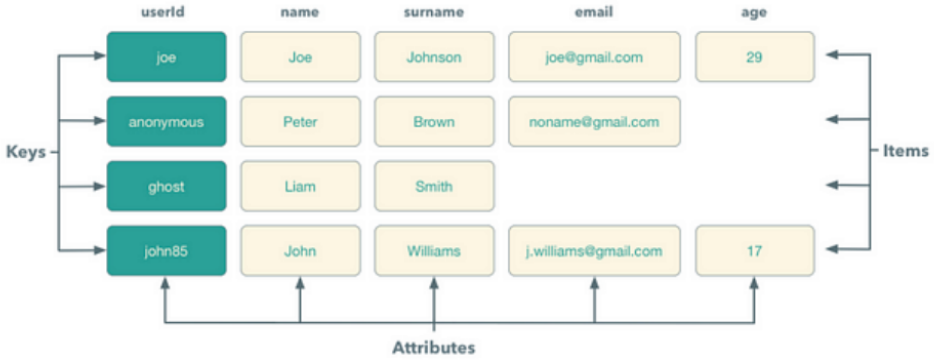


Figura - slide 32: componenti principali di DynamoDB: tables, items, attributes

- Ogni item deve avere una chiave primaria. DynamoDB supporta una chiave semplice, detta partition key, oppure una chiave composta da partition key e sort key.

Items In a Table Must Have a Key

- DynamoDB supports two different kinds of primary keys
  - A simple primary key, i.e., the partition key, which is an attribute that uniquely identifies an item
  - A composite primary key, i.e. the combination of a partition key ad a sort key

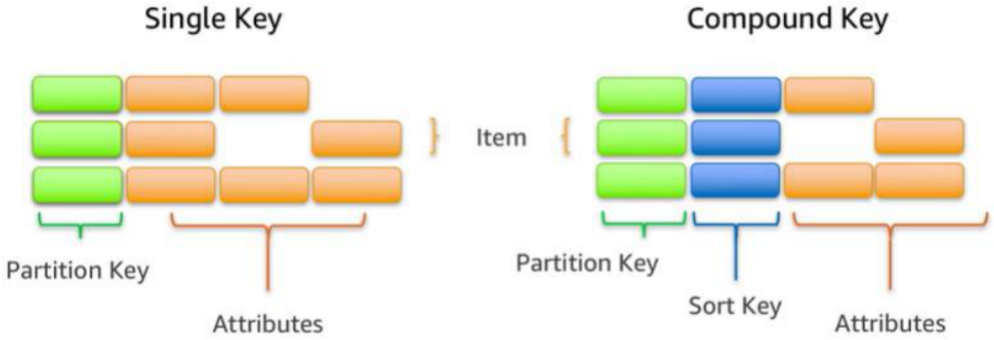


Figura - slide 33: chiave semplice e chiave composta in DynamoDB

- Per recuperare dati si possono usare query o scan. Query usa la primary key ed e efficiente; scan cerca condizioni su attributi non chiave e deve esaminare tutti gli item, quindi e meno efficiente.

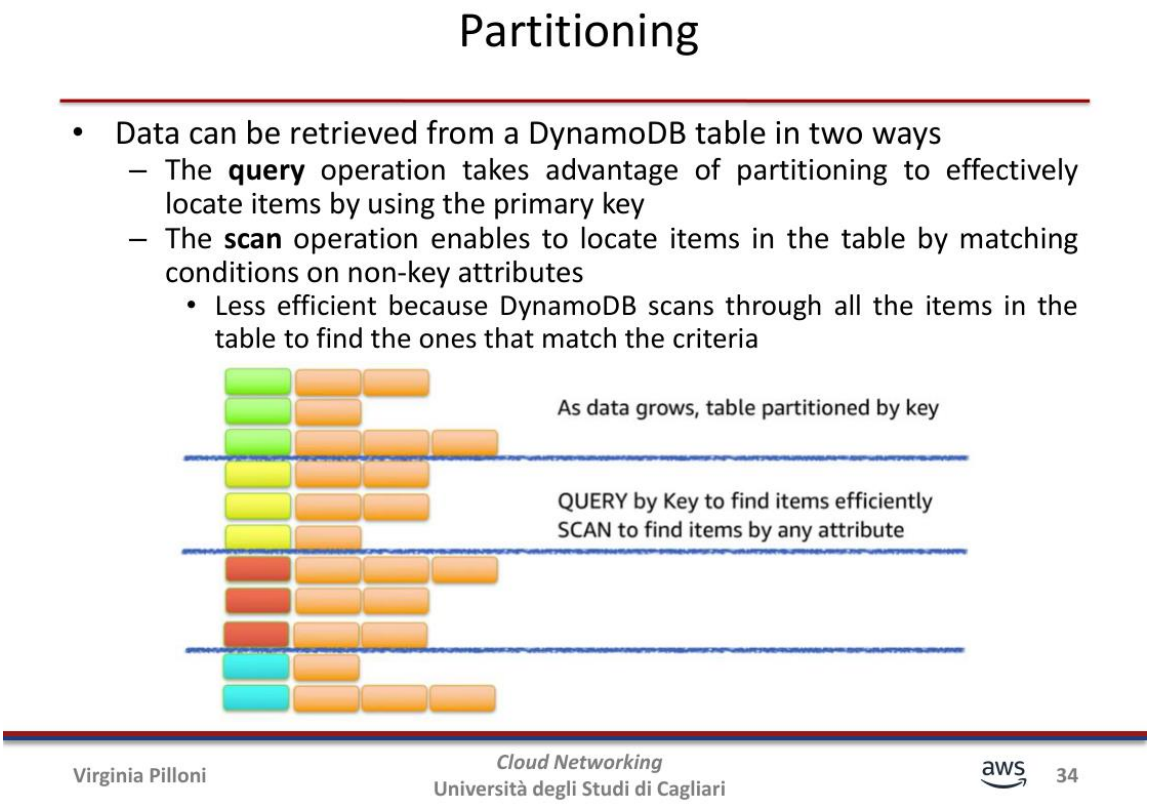


Figura - slide 34: differenza tra query e scan in DynamoDB

8. Amazon Redshift: data warehouse analitico

- Amazon Redshift e un data warehouse veloce e completamente gestito, usato per analizzare dati con SQL standard e strumenti di Business Intelligence.
- E pensato per query analitiche complesse contro petabyte di dati strutturati.

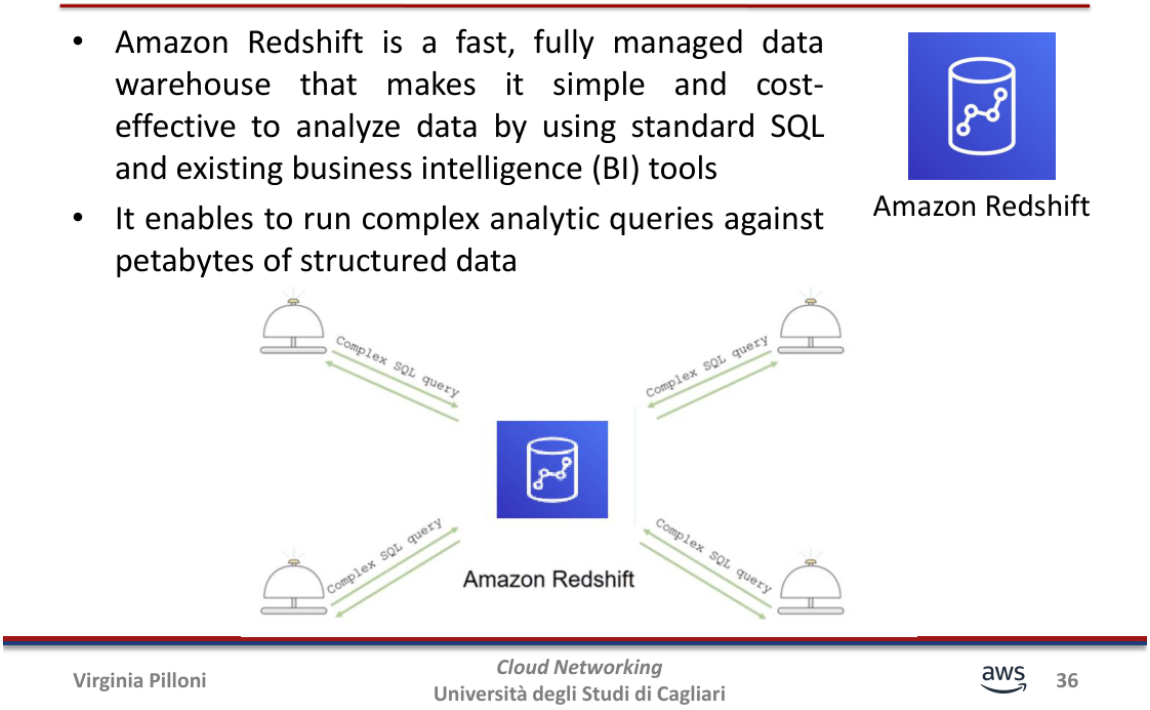


Figura - slide 36: Amazon Redshift come data warehouse fully managed

- L'architettura usa elaborazione parallela. Il leader node e il punto centrale di comunicazione e query processing: riceve le query, le analizza, crea il piano di esecuzione e assegna parti del lavoro ai compute nodes.
- I compute nodes eseguono il codice compilato e inviano risultati intermedi al leader node per l'aggregazione finale.

Parallel Processing Architecture

- The leader node is the central point of communication and query processing. It receives queries from client applications, parses them, and develops an execution plan. It compiles code for individual elements of the plan and assigns the code to individual compute nodes
- The compute nodes run the compiled code and send intermediate results back to the leader node for final aggregation

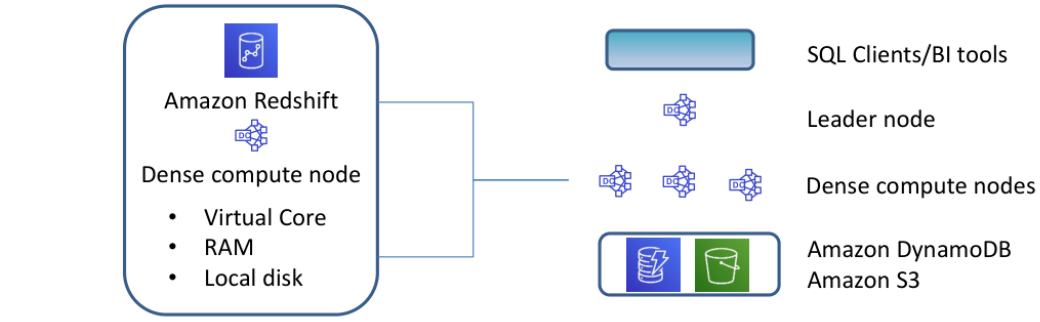


Figura - slide 37: architettura Redshift con leader node e compute nodes

9. Tabelle di confronto utili per l'esame

Servizio	Categoria	Problema risolto	Quando usarlo
Amazon S3	Object storage	Archiviare oggetti in bucket con scalabilita elevata	Backup, contenuti statici, media hosting, data lake, file applicativi
S3 Glacier	Archive storage	Conservare dati a costo molto basso	Archivi, compliance, dati acceduti raramente
Amazon EFS	File storage	File system condiviso e montabile da piu istanze	Home directory, web serving, CMS, analytics, workload Linux condivisi
Amazon Aurora	Relational database	Database SQL gestito compatibile MySQL/PostgreSQL	Applicazioni transazionali che richiedono alta disponibilita
Amazon DynamoDB	NoSQL database	Database key-value/document scalabile e a bassa latenza	Accessi rapidi, grandi volumi, dati flessibili, scalabilita orizzontale
Amazon Redshift	Data warehouse	Analisi SQL e BI su grandi volumi di dati strutturati	Query analitiche, reporting, business intelligence
Servizio	**Unita logica principale**	**Accesso tipico**	**Latenza/uso**
S3	Oggetto in bucket	API/URL/SDK/CLI	Millisecondi; dati attivi o archiviazione oggetti
Glacier	Archive in vault	API/SDK/CLI o lifecycle policy	Minuti/ore; archiviazione a basso costo
EFS	File system	Montaggio NFS da istanze EC2	File sharing a bassa latenza
DynamoDB	Item in table	API/SDK/query/scan	Bassa latenza a scala elevata
Redshift	Tabelle analitiche	SQL/BI tools	Analisi complesse su grandi dataset

10. Glossario essenziale

- **Object storage:** Modello di storage in cui i dati sono salvati come oggetti, non come blocchi o file system tradizionali.
- **Bucket:** Contenitore logico di Amazon S3 in cui vengono memorizzati gli oggetti.
- **Object:** File o dato memorizzato in S3. Puo arrivare fino a 5 TB.
- **Lifecycle policy:** Regola S3 che sposta o elimina oggetti automaticamente in base all'eta o ad altre condizioni.
- **Archive:** Unita base di storage in Amazon S3 Glacier.

- **Vault:** Contenitore Glacier per archivi.
- **Mount target:** Endpoint di rete usato dalle istanze EC2 per montare un file system EFS.
- **Relational database:** Database basato su tabelle, righe, colonne e relazioni, interrogato con SQL.
- **NoSQL:** Famiglia di database non relazionali progettati per dati flessibili e scalabilita orizzontale.
- **Partition key:** Attributo usato da DynamoDB per distribuire e identificare gli item.
- **Sort key:** Attributo aggiuntivo che, insieme alla partition key, forma una chiave primaria composta.
- **Query:** Operazione efficiente in DynamoDB che usa la primary key.
- **Scan:** Operazione meno efficiente che legge tutti gli item per cercare corrispondenze.
- **Data warehouse:** Sistema ottimizzato per analisi, reporting e query complesse su grandi volumi di dati.

11. Domande d'esame / ripasso con risposta

Domanda: **Che tipo di storage fornisce Amazon S3?**
Risposta: Amazon S3 fornisce object-level storage gestito. I file sono trattati come oggetti e salvati dentro bucket.

Domanda: **Che cosa e un bucket S3?**
Risposta: E un contenitore logico per oggetti. Viene creato in una Region AWS e il suo nome deve essere unico globalmente in Amazon S3.

Domanda: **Qual e la dimensione massima di un oggetto S3 secondo il PDF?**
Risposta: Un oggetto S3 puo avere dimensione massima pari a 5 TB.

Domanda: **Perche in S3 non si modifica solo un piccolo blocco di un file?**
Risposta: Perche S3 e object storage: dopo una modifica l'intero file aggiornato deve essere ricaricato, diversamente dallo storage a blocchi.

Domanda: **A cosa servono le lifecycle policies di S3?**
Risposta: Servono a spostare automaticamente gli oggetti tra classi di storage o eliminarli in base alla loro eta o a regole definite sul bucket.

Domanda: **Quando conviene usare S3 Intelligent-Tiering?**
Risposta: Quando il pattern di accesso e variabile o imprevedibile: il servizio sposta automaticamente gli oggetti verso il tier piu conveniente.

Domanda: **Qual e la differenza tra S3 Standard-IA e S3 One Zone-IA?**
Risposta: Entrambi sono per dati acceduti raramente con accesso rapido. Standard-IA usa piu Availability Zones; One Zone-IA salva in una sola Availability Zone e costa meno, ma offre minore resilienza.

Domanda: **Che cos'e Amazon S3 Glacier?**
Risposta: E un servizio/classe di storage per archiviazione sicura, durevole e a basso costo, pensato per dati recuperati raramente.

Domanda: **Quali sono le tre opzioni di retrieval di Glacier?**
Risposta: Expedited, Standard e Bulk. Expedited e piu rapido e costoso; Bulk e piu lento ma piu economico.

Domanda: **Come viene gestita la sicurezza in S3 Glacier?**
Risposta: L'accesso e controllato con IAM; i dati sono cifrati con AES-256; Amazon S3 Glacier gestisce le chiavi per l'utente.

Domanda: **Che cos'e Amazon EFS?**
Risposta: E un file system completamente gestito, elastico, condiviso e compatibile con NFSv4, utilizzabile da istanze EC2 Linux-based.

Domanda: **Che cosa sono i mount target in EFS?**
Risposta: Sono endpoint creati nelle subnet per permettere alle istanze EC2 di montare e accedere al file system EFS.

Domanda: **Che cos'e Amazon Aurora?**

Risposta: E un database relazionale fully managed, compatibile con MySQL e PostgreSQL, progettato per performance, disponibilita e automazione operativa.

Domanda: **Come Aurora supporta l'alta disponibilita?**
Risposta: Mantiene piu copie dei dati su piu Availability Zones, usa backup continui su Amazon S3, supporta read replica e instant crash recovery.

Domanda: **Qual e la differenza tra database relazionale e non relazionale?**
Risposta: Il relazionale usa tabelle, righe, colonne, schema fisso e SQL; il non relazionale usa modelli come key-value o document, schema dinamico e scalabilita orizzontale.

Domanda: **Che cos'e Amazon DynamoDB?**
Risposta: E un database NoSQL veloce e flessibile, con tabelle, item e attributi, storage virtualmente illimitato e throughput scalabile.

Domanda: **Qual e la differenza tra query e scan in DynamoDB?**
Risposta: Query usa la primary key ed e efficiente; scan cerca su attributi non chiave e deve esaminare tutti gli item, quindi e meno efficiente.

Domanda: **Che cos'e Amazon Redshift?**
Risposta: E un data warehouse fully managed per analisi su petabyte di dati strutturati usando SQL standard e strumenti di Business Intelligence.

Domanda: **Che ruolo ha il leader node in Redshift?**
Risposta: Riceve le query, le analizza, crea il piano di esecuzione e assegna il lavoro ai compute nodes.

Domanda: **Che ruolo hanno i compute nodes in Redshift?**
Risposta: Eseguono il codice compilato assegnato dal leader node e restituiscono risultati intermedi per l'aggregazione finale.