Appunti di Cloud Networking

AWS Automated Scaling and Monitoring

Obiettivo degli appunti

Capire come AWS distribuisce il traffico con Elastic Load Balancing, come monitora risorse e applicazioni con Amazon CloudWatch e come aumenta o riduce automaticamente la capacita con Amazon EC2 Auto Scaling e AWS Auto Scaling.

Mappa rapida del capitolo

Blocco	Che cosa studia	Idea chiave da ricordare
Elastic Load Balancing	Distribuzione del traffico tra piu target sani.	Il load balancer riceve traffico dai client e lo inoltra solo ai target healthy.
Amazon CloudWatch	Metriche, allarmi, eventi e monitoraggio.	Misura lo stato del sistema e puo attivare notifiche o azioni automatiche.
Amazon EC2 Auto Scaling	Aggiunta/rimozione automatica di istanze EC2.	Evita overprovisioning e underprovisioning adattando la capacita alla domanda.
AWS Auto Scaling	Piani di scaling per piu risorse AWS.	Coordina il dimensionamento di EC2, ECS, DynamoDB, Aurora e altre risorse.
Lab 6	Architettura bilanciata e scalabile.	AMI + ALB + Auto Scaling group + CloudWatch alarms.

1. Elastic Load Balancing

Elastic Load Balancing (ELB) e il servizio AWS che distribuisce il traffico applicativo o di rete in ingresso verso piu target, cioe verso risorse che possono elaborare le richieste. I target possono essere indirizzi IP, istanze EC2, container o funzioni Lambda. Il servizio puo lavorare in una singola Availability Zone oppure su piu Availability Zones, aumentando disponibilita e tolleranza ai guasti.

Idea da esame

Il load balancer non esegue l'applicazione: smista il traffico. L'applicazione viene eseguita dai target registrati. Il load balancer controlla anche lo stato dei target tramite health check e invia traffico solo a quelli sani.

Types of Load Balancers

- Elastic Load Balancing is available in three types

Application Load Balancer	Network Load Balancer	Classic Load Balancer (Previous Generation)
• Load balancing of HTTP and HTTPS traffic	• Load balancing of TCP, UDP, and TLS traffic where extreme performance is required	• Load balancing of HTTP, HTTPS, TCP, and SSL traffic
• Routes traffic to targets based on content of request • Provides advanced request routing targeted at the delivery of modern application architectures, including microservices and containers	• Routes traffic to targets based on IP protocol data • Can handle millions of requests per second while maintaining ultra-low latencies • Is optimized to handle sudden and volatile traffic patterns	• Load balancing across multiple EC2 instances
• Operates at the application layer (OSI model layer 7)	• Operates at the transport layer (OSI model layer 4)	• Operates at both the application and transport layers.

Virginia Pilloni — *Cloud Networking* — Università degli Studi di Cagliari — aws — 3

Figura - Tipi di load balancer disponibili in Elastic Load Balancing.

1.1 Tipi di load balancer

Tipo	Livello OSI / traffico	Quando usarlo	Punto forte
Application Load Balancer (ALB)	Livello applicazione, OSI layer 7. HTTP e HTTPS.	Applicazioni web, microservizi, container, routing basato sul contenuto della richiesta.	Routing avanzato e supporto moderno per architetture applicative.
Network Load Balancer (NLB)	Livello trasporto, OSI layer 4. TCP, UDP e TLS.	Traffico TCP molto variabile, milioni di richieste al secondo, latenze molto basse, IP statico o Elastic IP.	Prestazioni elevate e gestione di traffico improvviso.
Classic Load Balancer (CLB)	Generazione precedente. HTTP, HTTPS, TCP e SSL.	Scenari semplici o legacy con piu protocolli.	Semplice bilanciamento tra istanze EC2, ma meno moderno rispetto ad ALB/NLB.

1.2 Come funziona Elastic Load Balancing

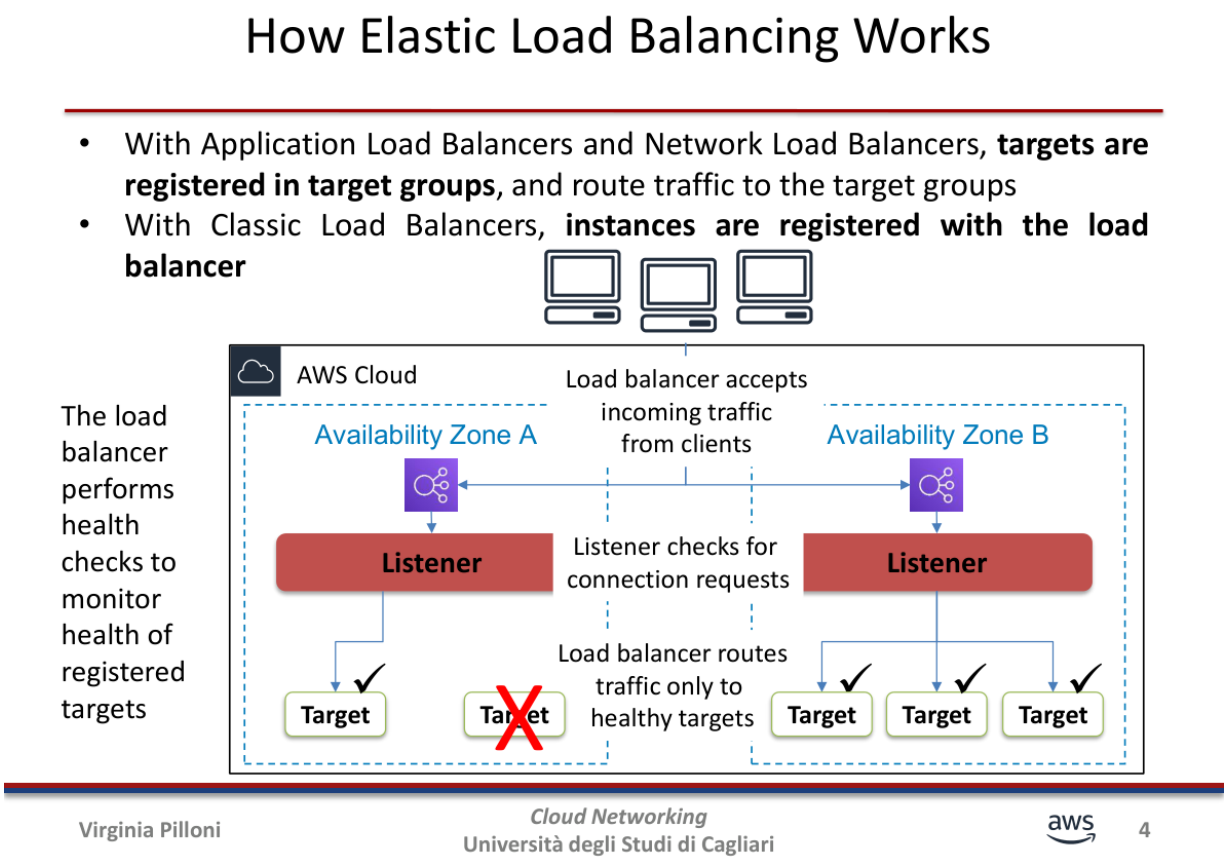


Figura - Funzionamento di ELB: client, listener, target groups e health checks.

1. Il client invia traffico verso il load balancer.

2. Il listener controlla le richieste di connessione in ingresso.

3. Il load balancer applica le regole configurate e inoltra il traffico al target group corretto.

4. I target registrati ricevono le richieste solo se risultano sani.

5. Gli health checks monitorano continuamente i target registrati.

6. Se un target diventa unhealthy, il traffico viene instradato verso altri target healthy.

Differenza importante

Con Application Load Balancer e Network Load Balancer i target sono registrati in target groups. Con Classic Load Balancer, invece, sono registrate direttamente le istanze con il load balancer.

1.3 Casi d'uso principali di ELB

- **Alta disponibilita e fault tolerance:** il traffico viene distribuito tra target sani in piu Availability Zones; se una AZ o un gruppo di target ha problemi, il traffico viene spostato verso target funzionanti.
- **Applicazioni containerizzate:** ELB si integra con Amazon ECS; i container possono essere registrati e deregistrati automaticamente e il load balancer puo rilevare dinamicamente le porte.

- **Elasticita e scalabilita:** ELB lavora insieme ad Amazon CloudWatch e Amazon EC2 Auto Scaling per adattare l'architettura alla domanda.
- **Uso dentro VPC:** puo creare un punto di ingresso pubblico oppure interno dentro una VPC e puo essere protetto tramite security group.
- **Hybrid load balancing:** puo bilanciare traffico tra risorse AWS e risorse on-premises.
- **Invocazione di Lambda via HTTP(S):** Application Load Balancer puo invocare funzioni Lambda per servire richieste HTTP/HTTPS in architetture serverless.

1.4 Monitoraggio dei load balancer

Strumento	Che cosa registra	A cosa serve
Amazon CloudWatch metrics	Metriche operative del load balancer e dei target.	Verificare prestazioni e creare allarmi quando una metrica supera una soglia.
Access logs	Informazioni dettagliate sulle richieste inviate al load balancer.	Analizzare traffico, debug, pattern di accesso.
AWS CloudTrail logs	Chi ha fatto cosa, quando e dove nelle chiamate API AWS.	Audit, tracciamento delle operazioni amministrative, sicurezza.

2. Amazon CloudWatch

Amazon CloudWatch e il servizio AWS usato per osservare risorse, applicazioni e comportamenti operativi. Serve a capire se una risorsa e sottoutilizzata, sovraccarica, non disponibile oppure fuori da una soglia accettabile.

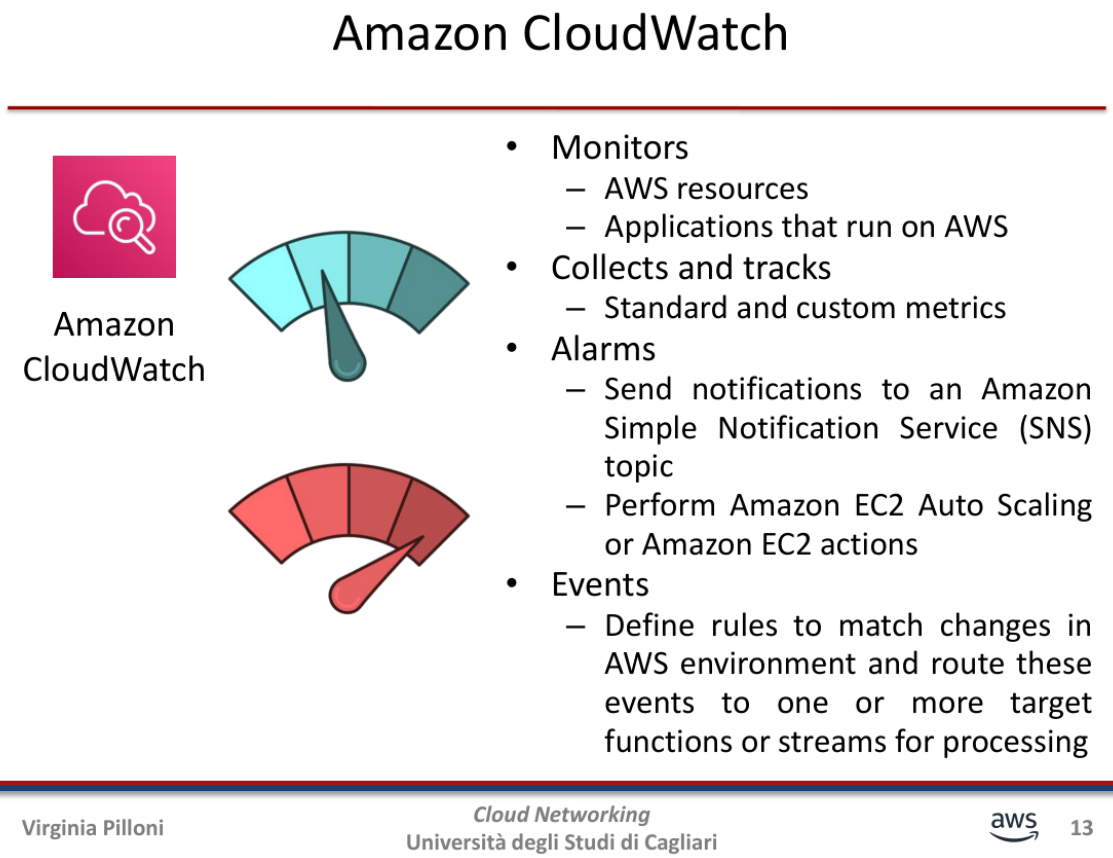


Figura - Amazon CloudWatch: metriche, allarmi ed eventi.

2.1 Perche serve il monitoraggio

Usare AWS in modo efficiente richiede visibilita. Senza monitoraggio non si sa quando aggiungere istanze EC2, se una applicazione sta rallentando per mancanza di capacita o quanta infrastruttura viene realmente utilizzata.

Domanda operativa	Servizio/concetto coinvolto	Risposta pratica
Quando devo lanciare piu istanze EC2?	CloudWatch + EC2 Auto Scaling	Creo un allarme su una metrica, per esempio CPU media > 60% per 5 minuti.
La mia applicazione sta soffrendo per mancanza di capacita?	Metriche CloudWatch	Controllo CPU, memoria custom, rete, latenza, host healthy/unhealthy.
Quanta infrastruttura sto usando davvero?	Metriche + tagging + analisi periodica	Misuro utilizzo reale e riduco risorse sovradimensionate.

2.2 Componenti principali di CloudWatch

Componente	Significato	Esempio
Metrics	Valori numerici raccolti nel tempo, standard o custom.	CPUUtilization di una EC2, numero di host sani in un load balancer.
Alarms	Regole che controllano una metrica rispetto a una condizione.	Se CPU media > 60% per 5 minuti, esegui scaling out.
Events / rules	Regole che intercettano cambiamenti nell'ambiente AWS e li inviano a target.	Avviare una funzione Lambda o una automazione quando accade un evento.
Actions	Azioni attivate quando un allarme cambia stato.	Notifica SNS, azione EC2, policy di Auto Scaling.

2.3 CloudWatch Alarms: come si costruisce un allarme

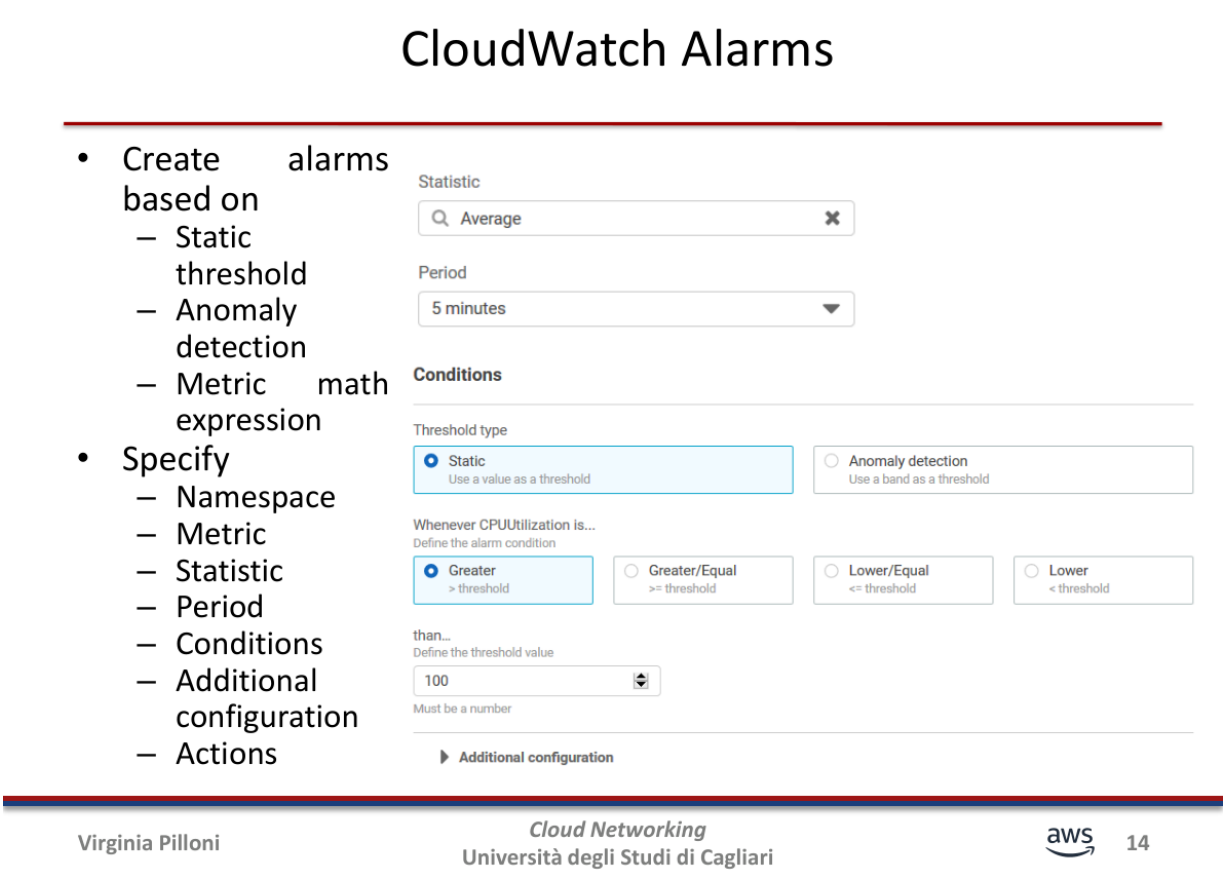


Figura - Configurazione di un CloudWatch Alarm: metrica, statistica, periodo e condizioni.

Fonte: slide 12 - CN - AWS Automated Scaling and Monitoring

1. Si sceglie il namespace, cioe il contesto del servizio AWS monitorato.

2. Si sceglie la metrica, per esempio CPUUtilization.

3. Si sceglie la statistic, per esempio Average, Maximum, Minimum o Sum.

4. Si sceglie il period, cioe l'intervallo temporale valutato.

5. Si definisce la condition, per esempio maggiore di 60.

6. Si aggiungono eventuali configurazioni aggiuntive.

7. Si sceglie l'azione: notifica, EC2 action o Auto Scaling action.

Allarme	Corretto?	Motivo
EC2: CPU media > 60% per 5 minuti	Si	Ha metrica, statistica, soglia e periodo.
RDS: connessioni simultanee > 10 per 1 minuto	Si	La condizione e chiara e misurabile.
S3: bucket size intorno a 3 per 1 giorno	No	"Intorno" non e una soglia valida: bisogna usare >, >=, <= o <.
ELB: numero di healthy hosts < 5 per 10 minuti	Si	La metrica e una soglia inferiore chiara.
EBS: volume di read operations > 1000 per 10 secondi	No	Manca una statistica, per esempio average o sum.

3. Amazon EC2 Auto Scaling

Amazon EC2 Auto Scaling serve a mantenere la disponibilita delle applicazioni aggiungendo o rimuovendo automaticamente istanze EC2 in base alla domanda. L'obiettivo e evitare sia sovradimensionamento sia insufficienza di risorse.

3.1 Perche lo scaling e importante

Scenario	Problema	Effetto
Overprovisioning	Si provisiona piu capacita di quella realmente usata.	Costo inutile: molte risorse restano idle.
Underprovisioning	Si provisiona meno capacita di quella richiesta.	Rallentamenti, errori, possibile perdita di utenti e fiducia.
Scaling corretto	La capacita segue la domanda.	Prestazioni stabili e costi piu efficienti.

Nel caso di traffico settimanale prevedibile, lo scaling puo adattarsi a pattern ricorrenti. Nel caso di picchi stagionali come Black Friday o Cyber Monday, lo scaling dinamico evita di tenere per tutto l'anno capacita dimensionata sul massimo picco.

3.2 Auto Scaling group

Un Auto Scaling group e una collezione di istanze EC2 trattate come gruppo logico per il dimensionamento e la gestione automatica.

Parametro	Significato
Minimum size	Numero minimo di istanze che devono rimanere attive.
Desired capacity	Numero desiderato di istanze in condizioni normali.
Maximum size	Numero massimo di istanze che il gruppo puo raggiungere.
Launch configuration / template	Definisce come creare le nuove istanze: AMI, tipo istanza, IAM role, security group, volumi EBS.
VPC e subnets	Definiscono dove lanciare le istanze.
Load balancer	Distribuisce il traffico verso le istanze del gruppo.

3.3 Scaling out e scaling in

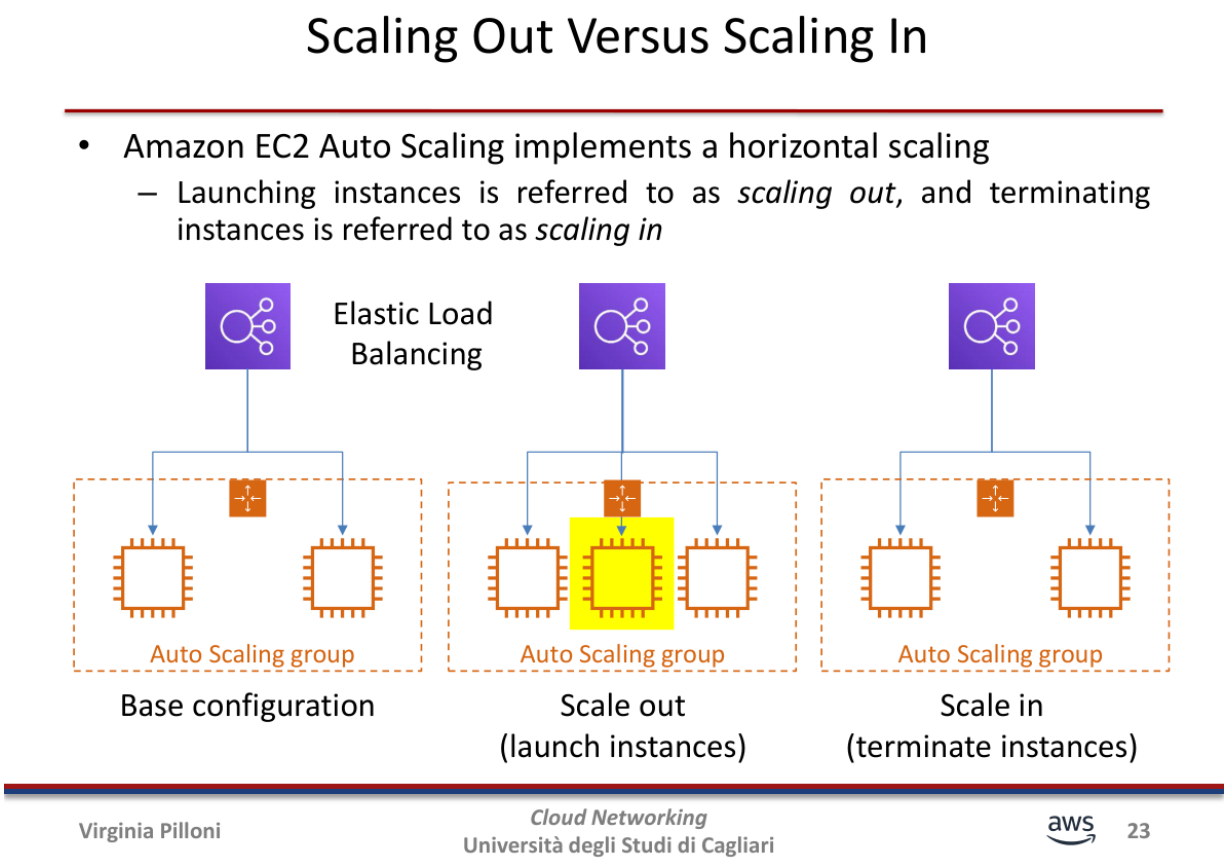


Figura - Scaling out: lancio nuove istanze; scaling in: terminazione delle istanze non necessarie.

Da non confondere

Amazon EC2 Auto Scaling implementa scaling orizzontale: aggiunge o rimuove istanze. Scaling out significa lanciare nuove istanze; scaling in significa terminarle.

3.4 Come funziona Amazon EC2 Auto Scaling

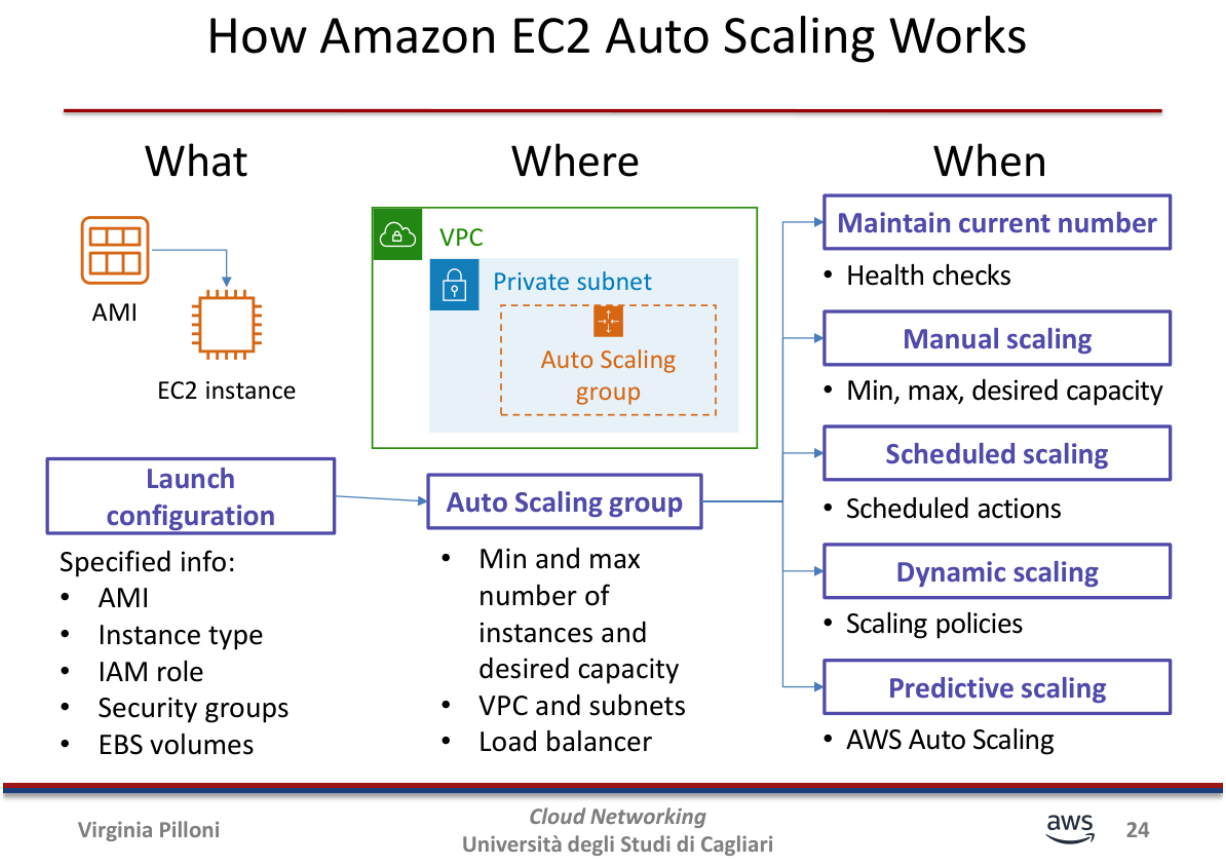


Figura - Logica What, Where, When di Amazon EC2 Auto Scaling.

Domanda	Cosa significa	Esempi dal PDF
What?	Quale istanza deve essere creata.	AMI, instance type, IAM role, security groups, EBS volumes.
Where?	Dove devono essere create le istanze.	VPC, subnets, load balancer, min/max/desired capacity.
When?	Quando scalare.	Manual scaling, scheduled scaling, dynamic scaling, predictive scaling, health checks.

3.5 Tipi di scaling

Tipo di scaling	Descrizione	Quando usarlo
Manual scaling	L'amministratore modifica manualmente min, max o desired capacity.	Test, correzioni puntuali, ambienti piccoli.
Scheduled scaling	Azioni pianificate in orari o giorni specifici.	Carichi prevedibili, per esempio traffico ricorrente settimanale.
Dynamic / on-demand scaling	CloudWatch rileva una metrica fuori soglia e attiva una scaling policy.	Carichi variabili e imprevedibili.
Predictive scaling	AWS usa previsioni basate su pattern storici per aumentare prima la capacita.	Carichi con pattern storici regolari ma non banali.
Maintain current number	Health checks sostituiscono istanze non sane per mantenere il numero previsto.	Mantenere disponibilita anche in caso di guasto.

3.6 Dynamic scaling con CloudWatch

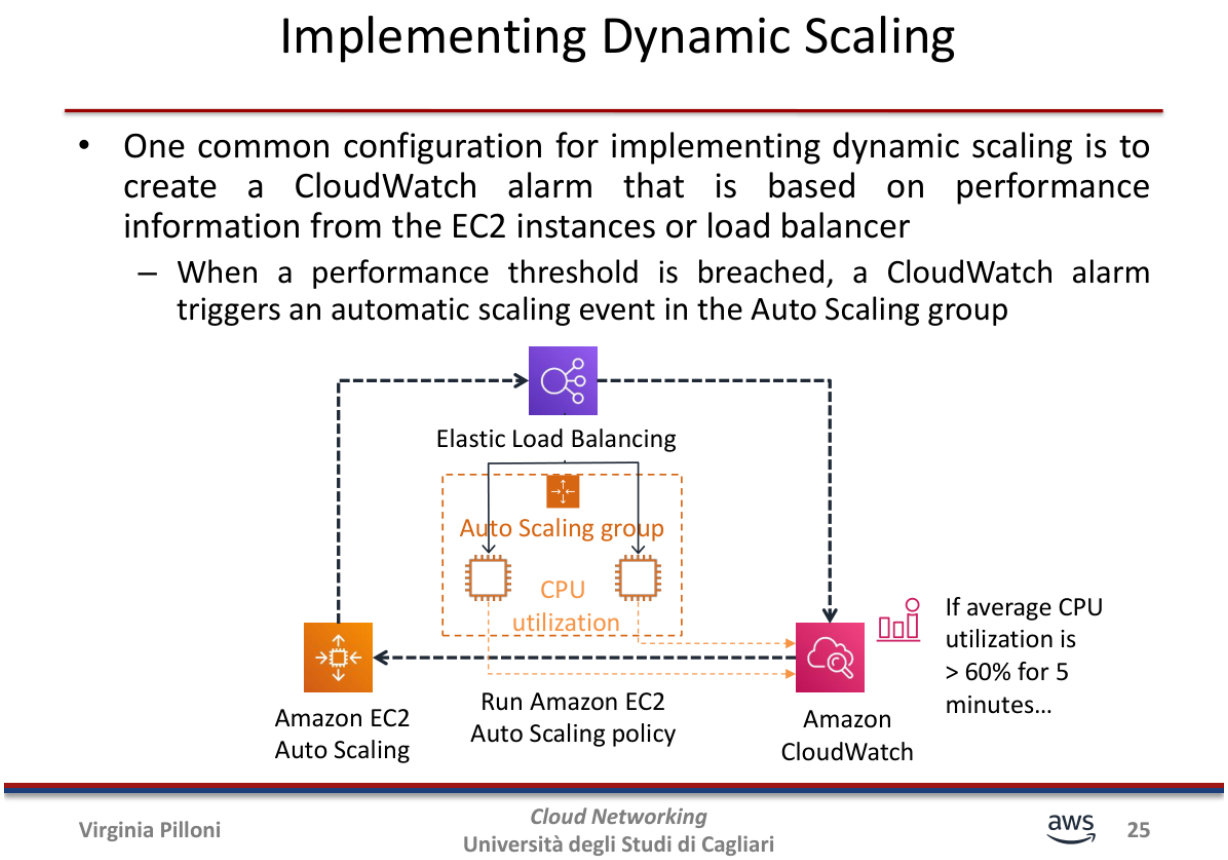


Figura - Esempio di dynamic scaling: CloudWatch alarm attiva una Auto Scaling policy.

1. Le istanze EC2 producono metriche, per esempio CPU utilization.

2. Amazon CloudWatch monitora la metrica.

3. Se la media della CPU supera una soglia, per esempio > 60% per 5 minuti, l'allarme cambia stato.

4. L'allarme attiva una policy di Amazon EC2 Auto Scaling.

5. L'Auto Scaling group lancia nuove istanze, cioe fa scaling out.

6. Il load balancer distribuisce traffico anche verso le nuove istanze healthy.

4. AWS Auto Scaling

AWS Auto Scaling e un servizio piu ampio rispetto ad Amazon EC2 Auto Scaling. Monitora applicazioni e regola automaticamente la capacita per mantenere prestazioni stabili e prevedibili al costo piu basso possibile.

Servizio	Che cosa scala
Amazon EC2	Istanze EC2 e Spot Fleets.
Amazon ECS	Task ECS.
Amazon DynamoDB	Tabelle e indici.
Amazon Aurora	Repliche Aurora.

EC2 Auto Scaling vs AWS Auto Scaling

EC2 Auto Scaling riguarda il gruppo di istanze EC2. AWS Auto Scaling e una interfaccia/piano di scaling piu generale che puo coordinare anche altre risorse, come ECS, DynamoDB e Aurora.

5. Lab 6 - Scale and Load Balance Your Architecture

Il laboratorio costruisce una architettura in cui il traffico passa attraverso un Application Load Balancer e viene distribuito verso istanze web gestite da un Auto Scaling group. La base dati e distribuita su RDS Primary e RDS Secondary in Availability Zones diverse.

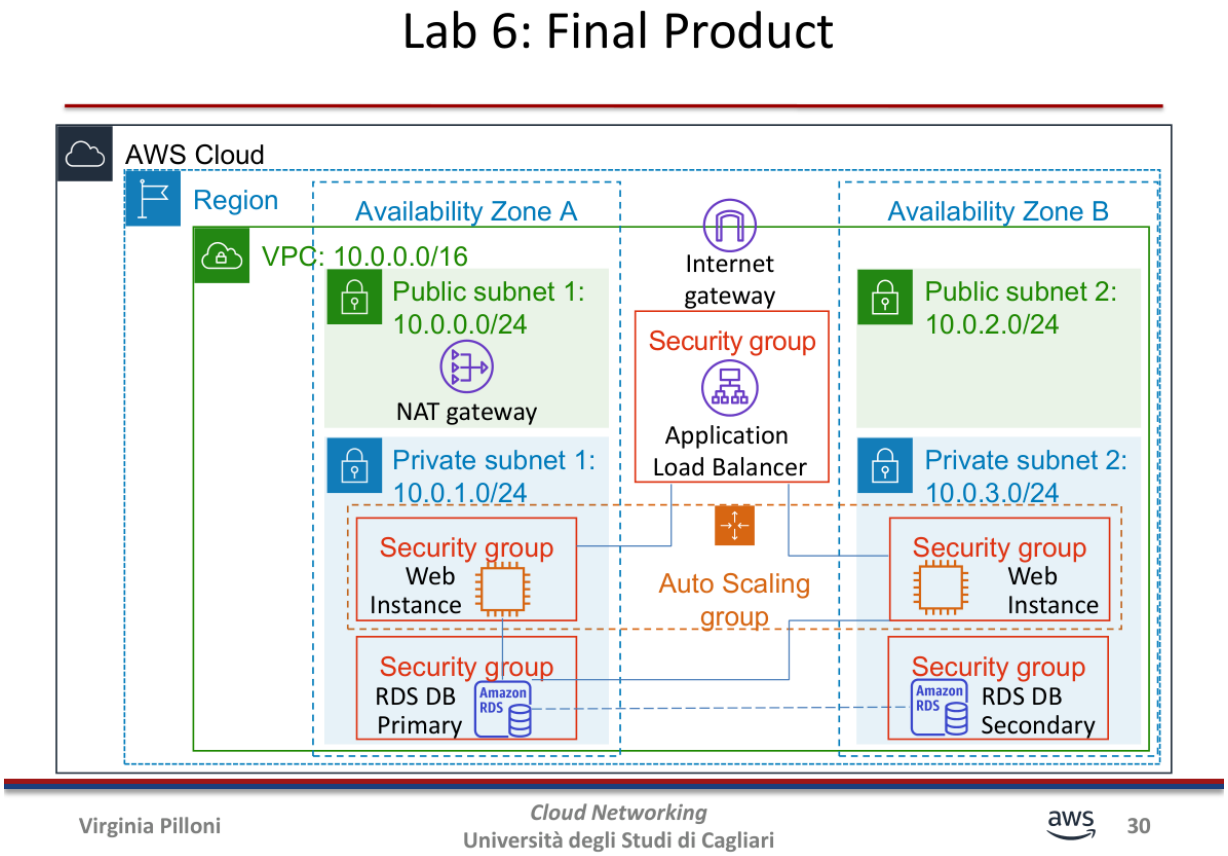


Figura - Prodotto finale del Lab 6: Application Load Balancer, Auto Scaling group, istanze web e RDS Multi-AZ.

Task	Scopo
Creare una AMI da una istanza in esecuzione	Usare l'istanza esistente come modello per creare nuove istanze identiche.
Creare un Application Load Balancer	Distribuire traffico HTTP/HTTPS verso istanze web healthy.
Creare launch configuration e Auto Scaling group	Definire come e dove creare nuove istanze automaticamente.
Scalare automaticamente nuove istanze in subnet private	Aumentare la capacita senza esporre direttamente le istanze a Internet.
Creare CloudWatch alarms e monitorare performance	Attivare scaling e osservare lo stato dell'infrastruttura.

Nota sul PDF

Nel laboratorio viene indicato che uno step relativo alla raccolta delle metriche del gruppo in CloudWatch e stato inserito erroneamente alla fine dello step 28 invece che nello step 29.

6. Tabella finale di ripasso

Concetto	Definizione breve	Parola chiave
Elastic Load Balancing	Distribuisce traffico verso piu target sani.	Traffic distribution
Application Load Balancer	Load balancer layer 7 per HTTP/HTTPS e routing avanzato.	Layer 7
Network Load Balancer	Load balancer layer 4 per TCP/UDP/TLS e latenze molto basse.	Layer 4
Classic Load Balancer	Load balancer precedente per HTTP/HTTPS/TCP/SSL.	Legacy
Target group	Gruppo di target verso cui ALB/NLB instradano il traffico.	Targets
Health check	Controllo periodico dello stato dei target.	Healthy/unhealthy
CloudWatch metric	Valore misurato nel tempo.	Metric
CloudWatch alarm	Condizione su una metrica che puo attivare azioni.	Alarm
Auto Scaling group	Gruppo logico di istanze EC2 scalate automaticamente.	Min/des/max
Scaling out	Aggiunta di nuove istanze.	Launch
Scaling in	Rimozione di istanze.	Terminate
AWS Auto Scaling	Piani di scaling per piu risorse AWS.	Scaling plan

7. Domande d'esame con risposta

Domanda 1: Che cos'e Elastic Load Balancing?

Risposta: E un servizio AWS che distribuisce traffico applicativo o di rete in ingresso verso piu target, come EC2, container, indirizzi IP o funzioni Lambda, in una o piu Availability Zones.

Domanda 2: Qual e il ruolo degli health checks in un load balancer?

Risposta: Gli health checks controllano lo stato dei target registrati. Il load balancer inoltra traffico solo ai target considerati healthy e smette di inviarlo ai target unhealthy.

Domanda 3: Quale load balancer si usa per traffico HTTP/HTTPS e routing basato sul contenuto?

Risposta: Application Load Balancer, perche opera al layer applicativo e supporta routing avanzato per applicazioni web, microservizi e container.

Domanda 4: Quale load balancer si usa per traffico TCP molto variabile e milioni di richieste al secondo?

Risposta: Network Load Balancer, perche opera al livello di trasporto, gestisce traffico TCP/UDP/TLS e mantiene latenze molto basse.

Domanda 5: Quale load balancer e considerato precedente generazione?

Risposta: Classic Load Balancer. Supporta HTTP, HTTPS, TCP e SSL, ma e meno adatto alle architetture moderne rispetto ad ALB e NLB.

Domanda 6: Quali strumenti si usano per monitorare un load balancer?

Risposta: Amazon CloudWatch metrics, access logs e AWS CloudTrail logs. CloudWatch misura prestazioni, access logs registrano richieste, CloudTrail traccia le interazioni API.

Domanda 7: Che cosa fa Amazon CloudWatch?

Risposta: Monitora risorse AWS e applicazioni, raccoglie metriche, consente di creare allarmi e puo attivare notifiche o azioni come Auto Scaling o azioni EC2.

Domanda 8: Quali elementi servono per configurare correttamente un CloudWatch alarm?

Risposta: Servono namespace, metrica, statistica, periodo, condizione, eventuale configurazione aggiuntiva e azioni da eseguire quando l'allarme cambia stato.

Domanda 9: Perche "bucket size around 3" non e una condizione valida per un allarme?

Risposta: Perche "around" non e una soglia valida. Un allarme deve usare condizioni precise come maggiore di, maggiore o uguale, minore di o minore o uguale.

Domanda 10: Che cos'e Amazon EC2 Auto Scaling?

Risposta: E un servizio che mantiene la disponibilita delle applicazioni aggiungendo o rimuovendo automaticamente istanze EC2 secondo condizioni definite, health checks o pianificazioni.

Domanda 11: Che cos'e un Auto Scaling group?

Risposta: E una collezione di istanze EC2 gestite come gruppo logico per scaling automatico e gestione. Ha minimum size, desired capacity e maximum size.

Domanda 12: Che differenza c'e tra scaling out e scaling in?

Risposta: Scaling out significa lanciare nuove istanze per aumentare capacita. Scaling in significa terminare istanze per ridurre capacita quando la domanda diminuisce.

Domanda 13: Come si implementa un caso tipico di dynamic scaling?

Risposta: Si crea un CloudWatch alarm su una metrica, per esempio CPU media > 60% per 5 minuti. Quando la soglia viene superata, l'allarme attiva una scaling policy dell'Auto Scaling group.

Domanda 14: Qual e la differenza tra Amazon EC2 Auto Scaling e AWS Auto Scaling?

Risposta: Amazon EC2 Auto Scaling gestisce gruppi di istanze EC2. AWS Auto Scaling consente di costruire piani di scaling anche per risorse come ECS tasks, DynamoDB e Aurora replicas.

Domanda 15: Qual e lo scopo del Lab 6?

Risposta: Creare una architettura scalabile e bilanciata con AMI, Application Load Balancer, launch configuration, Auto Scaling group, istanze web in private subnet e CloudWatch alarms per monitorare le prestazioni.

8. Errori tipici da evitare

- Confondere load balancer e Auto Scaling: il load balancer distribuisce traffico, Auto Scaling crea o termina istanze.
- Pensare che CloudWatch faccia scaling da solo: CloudWatch misura e allarma; lo scaling avviene tramite policy collegate ad Auto Scaling.
- Confondere scaling verticale e orizzontale: EC2 Auto Scaling aggiunge/rimuove istanze, quindi e scaling orizzontale.
- Dimenticare gli health checks: senza controlli di salute, il traffico potrebbe andare verso target non funzionanti.

- Usare condizioni vaghe negli allarmi: le soglie devono essere confronti precisi su metriche e statistiche definite.
- Scegliere il load balancer sbagliato: ALB per HTTP/HTTPS avanzato, NLB per TCP/UDP/TLS ad alte prestazioni, CLB solo per scenari legacy o semplici.

9. Riassunto in 10 righe

1. Elastic Load Balancing distribuisce traffico verso target sani.

2. I target possono essere EC2, IP, container o Lambda.

3. ALB lavora al layer 7 ed e adatto ad applicazioni web e microservizi.

4. NLB lavora al layer 4 ed e adatto a traffico TCP/UDP/TLS ad alte prestazioni.

5. CloudWatch raccoglie metriche e permette di creare allarmi.

6. Un CloudWatch alarm deve avere metrica, statistica, periodo e soglia chiara.

7. EC2 Auto Scaling mantiene disponibilita e ottimizza i costi.

8. Un Auto Scaling group usa minimum size, desired capacity e maximum size.

9. Scaling out aggiunge istanze; scaling in le rimuove.

10. AWS Auto Scaling estende il concetto a piu servizi AWS, non solo EC2.