Cloud Networking

Appunti completi - Cloud Architectures

Obiettivo degli appunti

- Spiegare passo passo i meccanismi e le architetture cloud del PDF.
- Collegare ogni architettura al problema che risolve: scalabilità, disponibilità, isolamento, storage, rete o disaster recovery.
- Preparare una risposta da esame: definizione, componenti, flusso operativo, criticità e raccomandazioni.

Struttura consigliata per lo studio: prima i meccanismi infrastrutturali, poi le architetture fondamentali, poi quelle avanzate e specializzate. Le domande d’esame finali hanno la risposta subito sotto, come richiesto.

Indice sintetico

1. 1. Visione generale delle cloud architectures
2. 2. Cloud infrastructure mechanisms
3. 3. Fundamental cloud architectural models
4. 4. Advanced cloud architectures
5. 5. Specialized cloud architectures
6. 6. Edge, fog, metacloud e federated cloud application
7. 7. Tabelle di confronto e schemi da esame
8. 8. Domande d’esame con risposta

1. Visione generale

Una cloud architecture non è solo un insieme di macchine virtuali. È un modello organizzato di componenti, meccanismi e regole automatiche che permette al cloud di offrire elasticità, disponibilità, isolamento, monitoraggio e controllo dei costi.

Concetto	Significato pratico	Problema risolto
Meccanismo cloud	Componente riutilizzabile, ad esempio hypervisor, load balancer, usage monitor.	Fornisce una funzione di base dell'infrastruttura.
Architettura cloud	Combinazione di più meccanismi secondo un modello preciso.	Risolve un problema sistemico: scalabilità, fault tolerance, storage dinamico, rete elastica.
Automazione	Uso di listener, monitor, VIM, engine e policy.	Riduce intervento manuale e tempi di reazione.
Resource pool	Insieme di risorse omogenee o organizzate in pool.	Permette provisioning e scaling dinamico.

Idea chiave da ricordare

- Le architetture cloud trasformano risorse statiche in risorse programmabili e dinamiche.
- Quasi tutte le architetture hanno tre elementi ricorrenti: monitoraggio, decisione automatica, azione di provisioning/replica/migrazione.
- In sede d'esame conviene sempre spiegare: cosa monitora, cosa decide, quale risorsa modifica e quale problema elimina.

2. Cloud Infrastructure Mechanisms

I cloud infrastructure mechanisms sono i mattoni tecnici su cui vengono costruite le architetture cloud. Nel PDF sono elencati virtual server, container, logical network perimeter, hypervisor, cloud storage device, cloud usage monitor, resource replication, ready-made environment e load balancer.

Meccanismo	Funzione	Dove serve
Virtual server	Astrazione software di un server fisico.	IaaS, provisioning rapido, isolamento tra tenant.
Container	Ambiente leggero che usa solo il sottoinsieme di OS necessario.	Microservizi, portabilità, avvio rapido.
Logical network perimeter	Confine virtuale di rete per isolare risorse cloud.	Sicurezza, segmentazione, collegamenti VPN.
Hypervisor	Crea e gestisce VM su server fisici.	Virtualizzazione e consolidamento risorse.
Cloud storage device	Espone storage file, block, object o dataset.	Persistenza, backup, database, object storage.
Cloud usage monitor	Raccoglie metriche di uso e stato.	Billing, scaling, health check.
Resource replication	Duplica risorse IT cloud.	Alta disponibilità, scaling out, disaster recovery.
Ready-made environment	Ambiente PaaS preconfigurato.	Sviluppo e deployment rapido.
Load balancer	Distribuisce richieste tra risorse equivalenti.	Scalabilità orizzontale e fault tolerance.

2.1 Logical Network Perimeter

Il logical network perimeter è il confine logico che separa un ambiente di rete dal resto della rete. Non è necessariamente un muro fisico: è una delimitazione virtuale che può racchiudere risorse cloud distribuite fisicamente.

- **Componenti:** virtual firewall, virtual network, regole di accesso, eventualmente VPN.
- **Scopo:** isolare un gruppo di risorse e controllare il traffico in ingresso e in uscita.
- **Esempio:** un perimetro contiene l'ambiente on-premises del consumer, l'altro il cloud provider; una VPN protegge la comunicazione tra i due.

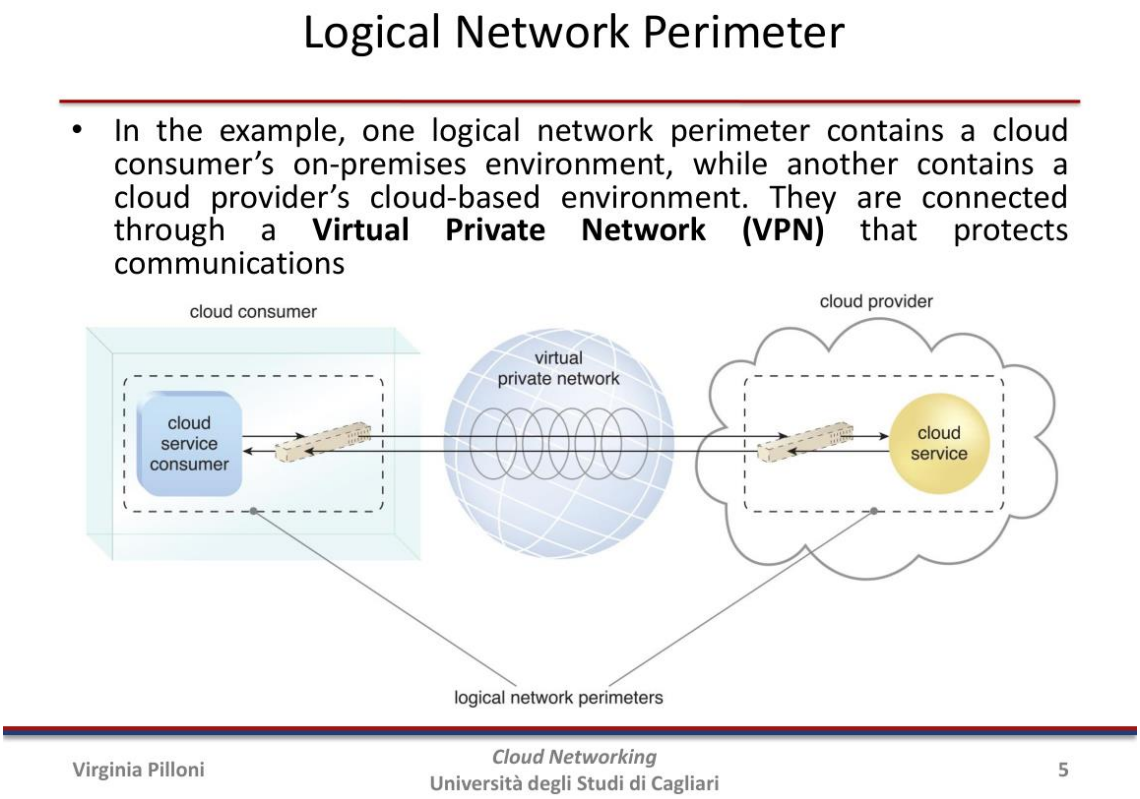


Figura - slide 5: due perimetri logici collegati tramite VPN.

Errore da evitare

- Non dire che il logical network perimeter è per forza un isolamento fisico. È un isolamento logico: può essere implementato su infrastruttura condivisa, ma con confini virtuali e controlli di rete.

2.2 Hypervisor e VIM

L'hypervisor è il meccanismo che genera e gestisce istanze di virtual server a partire da un server fisico. In cloud non basta avere un singolo hypervisor: per amministrare più hypervisor distribuiti serve un Virtual Infrastructure Manager, cioè un componente di controllo centrale.

- **Hypervisor:** crea VM, assegna CPU/RAM virtuali, consente accensione, spegnimento e modifica della capacità.
- **VIM:** coordina più hypervisor, conosce lo stato dei server fisici e può attivare migrazioni o riallocazioni.
- **Punto critico:** se un hypervisor non è ridondato, il suo guasto impatta tutte le VM ospitate su quel nodo fisico.

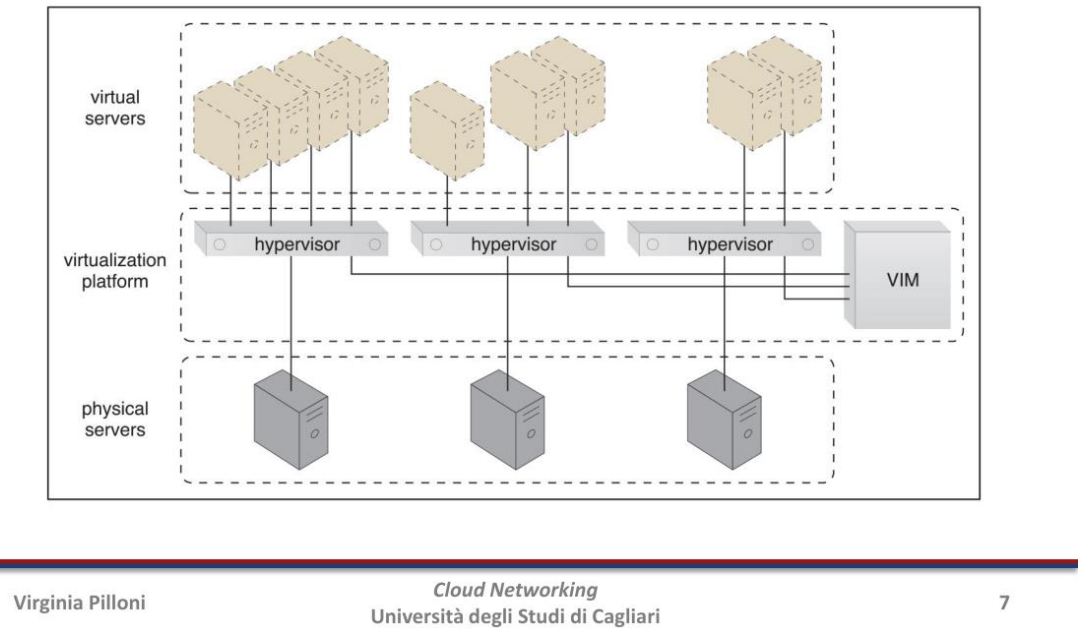


Figura - slide 7: più hypervisor coordinati da un VIM sopra server fisici.

2.3 Cloud Storage Devices

Il cloud storage device rappresenta dispositivi di memorizzazione progettati per essere esposti tramite servizi cloud. Il PDF distingue quattro unità logiche fondamentali: file, block, dataset e object.

Tipo	Descrizione	Accesso tipico	Esempio d'uso
File	Collezione di dati organizzata in cartelle.	POSIX, NFS, CIFS.	Home directory, condivisione file.
Block	Unità minima vicina all'hardware, indirizzabile singolarmente.	iSCSI, FC, FCoE, LUN.	Volume per VM, database transazionale.
Dataset	Dati strutturati in tabelle o record.	SQL o NoSQL API.	Database, analytics.
Object	Dato + metadati esposto come risorsa web.	REST/HTTP.	Bucket, archivi, media storage.

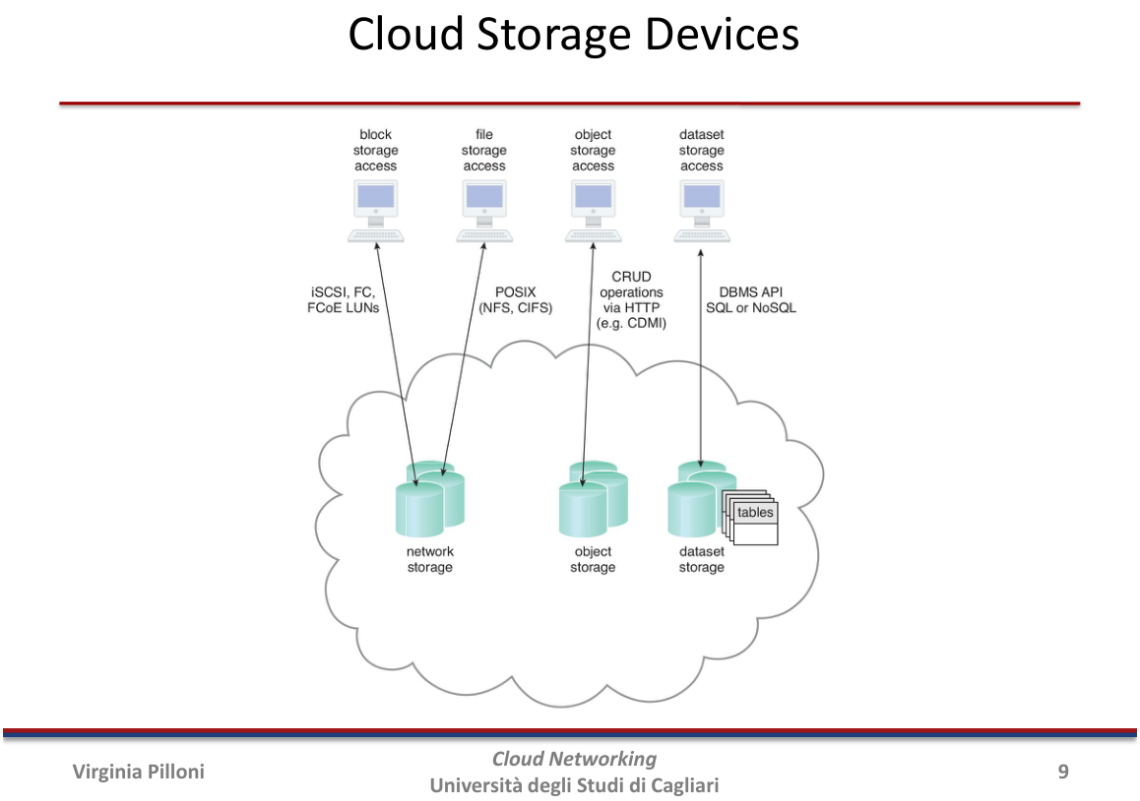


Figura - slide 9: modelli di accesso allo storage cloud.

2.4 Cloud Usage Monitor

Il cloud usage monitor è un programma autonomo e leggero che raccoglie e processa dati di utilizzo delle risorse. È fondamentale perché molte architetture automatiche decidono cosa fare sulla base delle metriche raccolte.

Tipo di agent	Come funziona	Quando è utile
Monitoring agent	Si posiziona lungo il percorso di comunicazione e osserva i flussi.	Analisi trasparente dei dataflow e logging.
Resource agent	Interagisce con software specializzato della risorsa e rileva eventi osservabili.	Monitoraggio di start, stop, suspend, resume, vertical scaling.
Polling agent	Interroga periodicamente le risorse.	Controllo di uptime, downtime e stato di servizio.

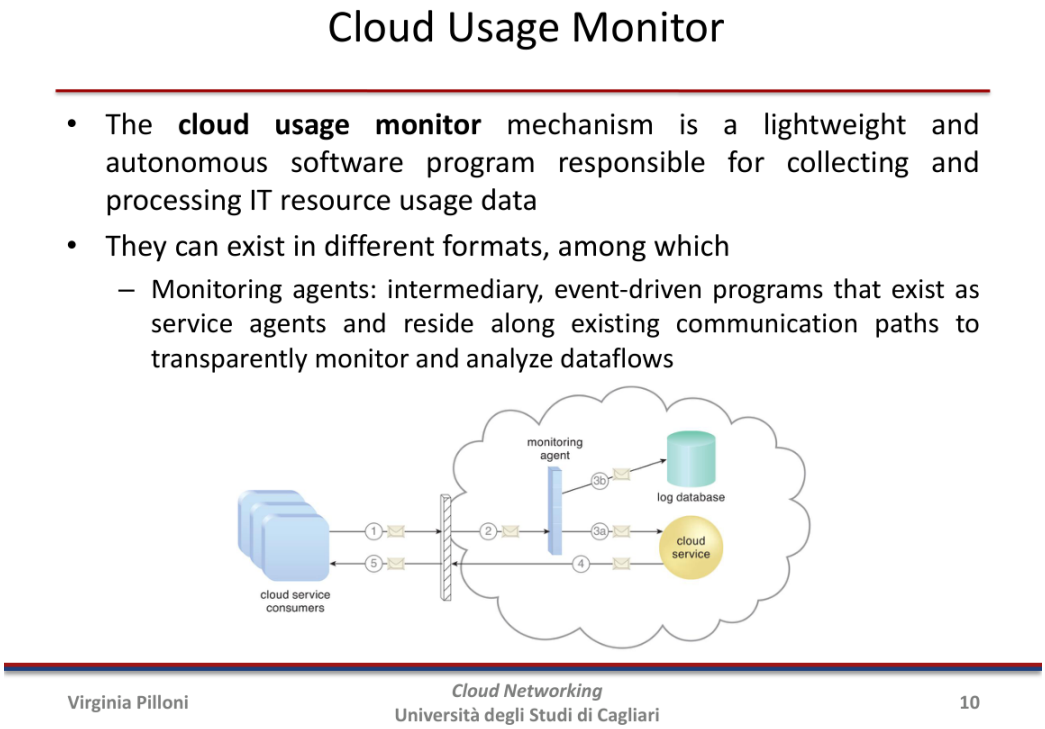


Figura - slide 10: monitoring agent lungo il percorso di comunicazione.

Flusso logico del monitoraggio

1. La risorsa o il servizio genera dati di utilizzo o eventi.
2. L'agent raccoglie le metriche in modo continuo, event-driven oppure tramite polling.
3. I dati vengono salvati in log o database di monitoraggio.
4. Una policy o un listener usa quelle metriche per attivare scaling, billing, failover o alert.

2.5 Resource Replication

La resource replication duplica risorse cloud-based. Serve sia per aumentare capacità sia per aumentare resilienza. Un caso classico è la creazione di più VM a partire da una virtual server image memorizzata nello storage.

- **Per scalabilità:** crea istanze aggiuntive quando cresce il carico.
- **Per disponibilità:** mantiene copie ridondanti pronte in caso di guasto.
- **Per disaster recovery:** replica risorse critiche in una regione o sito remoto.

2.6 Ready-Made Environment

Il ready-made environment è tipico del modello PaaS: una piattaforma cloud predefinita e già pronta, con risorse installate come database, middleware, strumenti di sviluppo e governance tool. Il consumer si concentra su sviluppo e deployment, non sulla preparazione dell'infrastruttura.

2.7 Load Balancer

Il load balancer è un runtime agent che distribuisce richieste su più risorse equivalenti. È alla base dello scaling orizzontale: invece di potenziare un'unica risorsa, si aggiungono risorse identiche e si bilancia il carico.

- **Vantaggio:** riduce sovraccarico e migliora disponibilità.

- **Rischio:** se è singolo e non ridondato può diventare single point of failure.
- **Condizione:** le risorse dietro il bilanciatore devono essere equivalenti o compatibili con la stessa funzione applicativa.

3. Fundamental Cloud Architectural Models

Le architetture fondamentali combinano i meccanismi appena studiati. Sono modelli ricorrenti per costruire cloud elastici, scalabili e resilienti.

3.1 Resource Pooling Architecture

La resource pooling architecture organizza risorse IT identiche in pool sincronizzati. Il cloud può così allocare risorse da un insieme comune invece di gestire ogni server, CPU, memoria o rete separatamente.

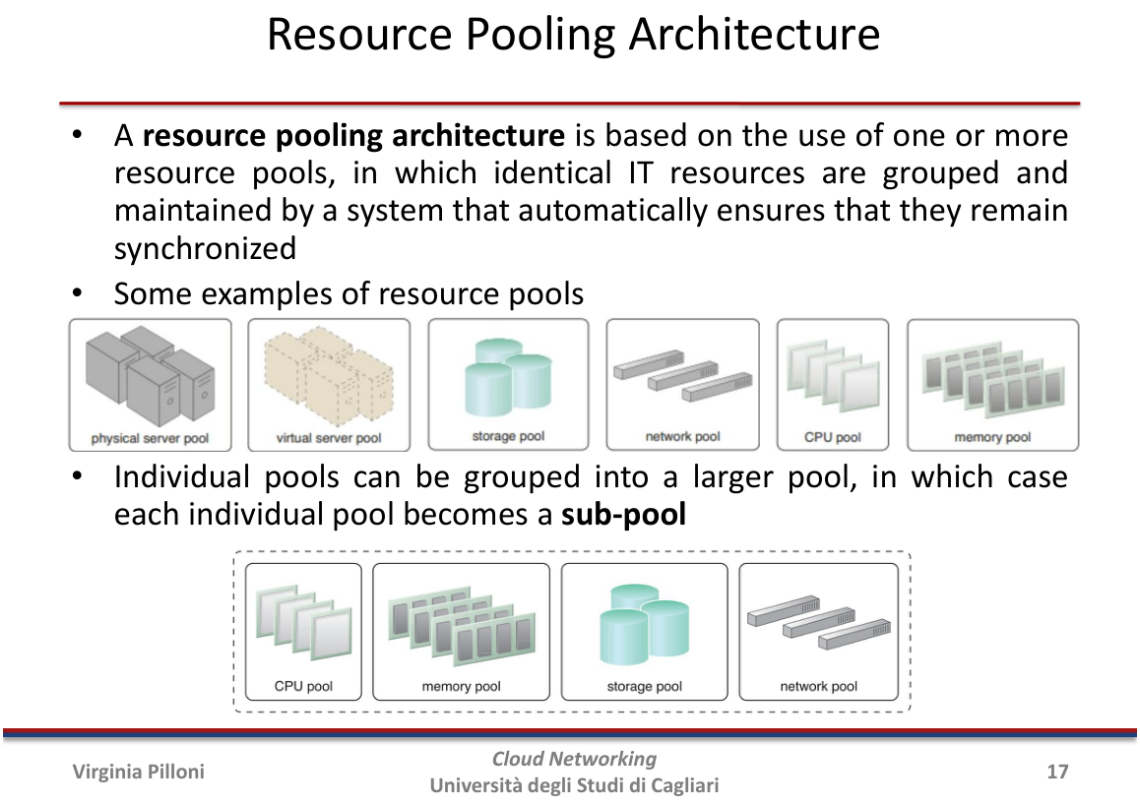


Figura - slide 17: pool di server, VM, storage, rete, CPU e memoria.

Tipo di pool	Cosa contiene	Uso tipico
Physical server pool	Server fisici omogenei.	Hosting di hypervisor e VM.
Virtual server pool	VM già disponibili o replicabili.	Provisioning rapido.
CPU/memory pool	Capacità computazionale aggregata.	Elastic resource capacity.
Storage pool	Dischi, LUN, volumi.	Elastic disk provisioning e tiering.
Network pool	Porte, uplink, bandwidth.	Elastic network capacity.

I pool possono essere parent, sibling o nested. I nested pool sono utili quando un'organizzazione vuole assegnare sotto-pool a reparti diversi; i sibling pool isolano risorse fisicamente raggruppate.

3.2 Dynamic Scalability Architecture

La dynamic scalability architecture usa condizioni predefinite di scaling per allocare dinamicamente risorse da un pool. Lo scopo è seguire la domanda reale: aggiungere capacità quando serve e recuperare risorse quando non servono più.

Tipo di scaling	Descrizione	Esempio
Horizontal scaling	Duplica risorse o istanze dello stesso tipo.	Aggiungere nuove VM o repliche di servizio.
Vertical scaling	Aumenta o riduce la capacità di una singola risorsa.	Più CPU/RAM a una VM.
Dynamic relocation	Sposta una risorsa su un host più capiente.	Migrazione VM verso server meno carico.

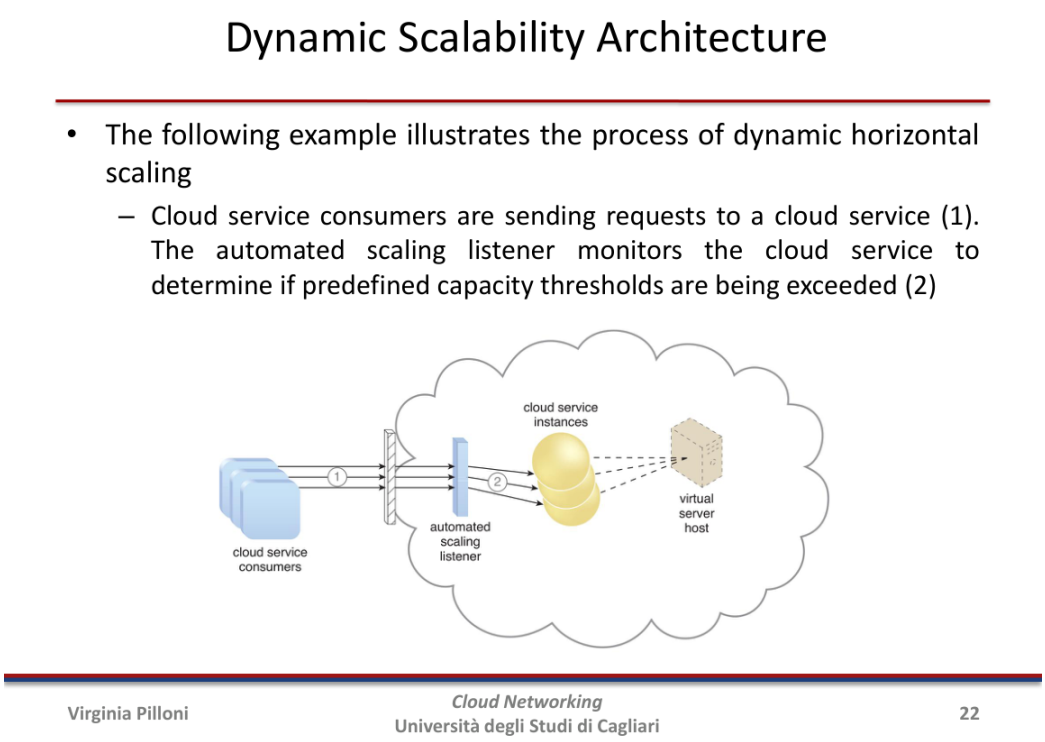


Figura - slide 22: inizio del monitoraggio da parte dell'automated scaling listener.

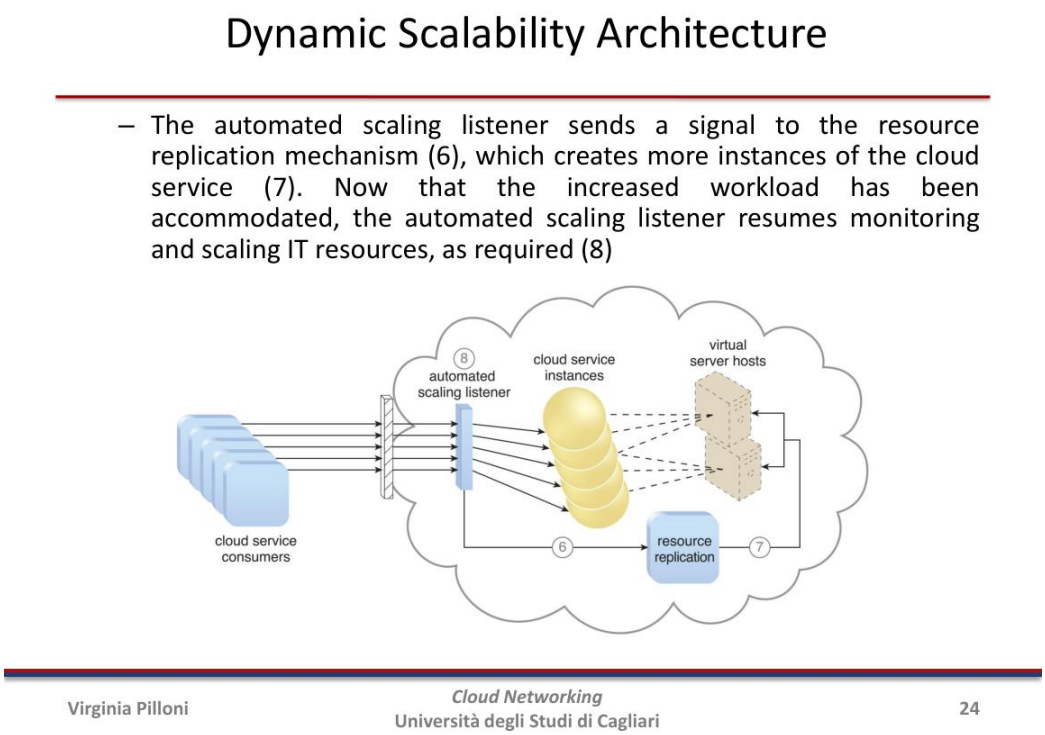


Figura - slide 24: creazione di più istanze tramite resource replication.

Flusso passo passo dello scaling orizzontale dinamico

1. I consumer inviano richieste al cloud service.
2. L'automated scaling listener monitora carico e soglie.
3. Le richieste aumentano e superano la soglia prestazionale.
4. Il listener applica la scaling policy e decide se il servizio è scalabile.
5. Il listener segnala il resource replication mechanism.
6. La replica crea nuove istanze del servizio.
7. Il carico viene assorbito dalle istanze aggiuntive e il listener continua a monitorare.

Criticità

- La soglia deve essere scelta con attenzione: troppo bassa causa scaling inutile e costoso; troppo alta causa degrado prima della reazione.
- Serve anche una policy di scale-in per rilasciare risorse ed evitare sprechi.
- Lo scaling orizzontale funziona meglio con servizi stateless o con stato esternalizzato.

3.3 Workload Distribution Architecture

La workload distribution architecture scala orizzontalmente aggiungendo risorse identiche e distribuendo il workload con un load balancer. Il risultato è un utilizzo più equilibrato: meno sovrautilizzo su una risorsa e meno sotto-utilizzo su altre.

- **Componenti:** load balancer, risorse replicate, logica di routing, eventuali health checks.
- **Flusso:** richieste -> load balancer -> scelta risorsa disponibile -> esecuzione servizio.
- **Collo di bottiglia:** il load balancer stesso e l'algoritmo di bilanciamento possono diventare critici.

- **Raccomandazione:** usare bilanciatori ridondati e health check per evitare invio verso risorse guaste.

3.4 Service Load Balancing Architecture

È una variante specializzata della workload distribution architecture per scalare implementazioni di cloud service. Le copie del servizio vengono organizzate in un resource pool e il carico viene distribuito tra host server.

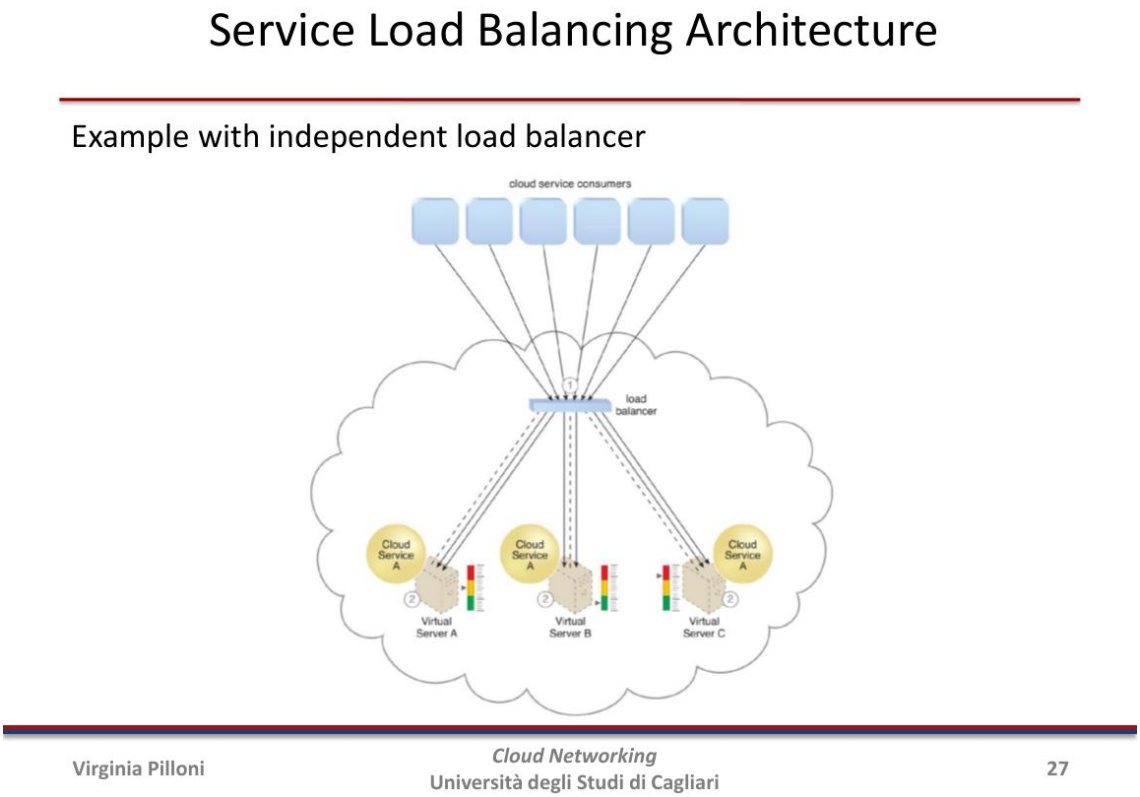


Figura - slide 27: esempio con load balancer indipendente.

Modello	Come funziona	Pro	Contro
Load balancer indipendente	Il bilanciatore è separato dai server del servizio.	Chiaro, gestibile, centralizzato.	Può diventare punto critico se non ridondato.
Load balancer built-in	La logica di bilanciamento è integrata nell'applicazione o nel server primario.	Meno componenti esterni.	Più complesso da progettare; rischio di dipendenza dal nodo primario.

3.5 Load-Balanced Virtual Server Instances Architecture

Questa architettura introduce un sistema di capacity watchdog che calcola dinamicamente il carico delle virtual server instances e distribuisce le VM su host fisici disponibili. Serve a evitare server fisici sovraccarichi e spreco di capacità su server sotto-utilizzati.

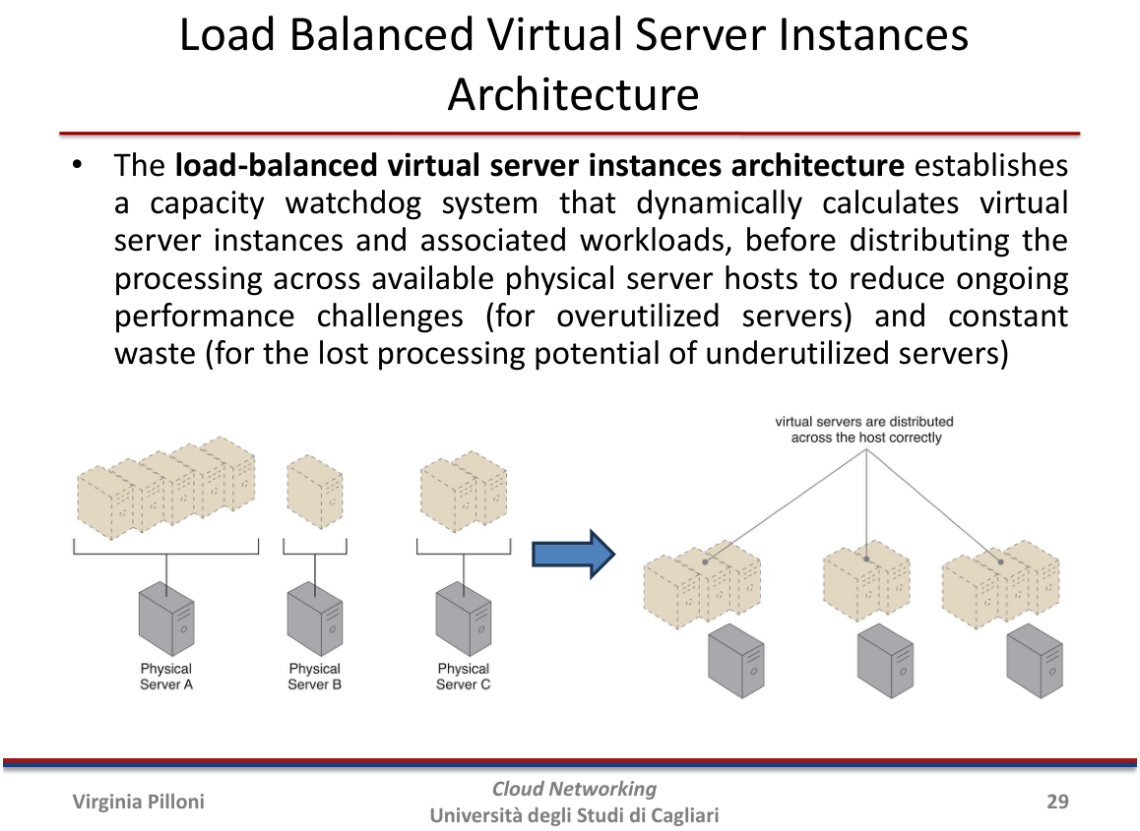


Figura - slide 29: ridistribuzione delle VM tra host fisici per ridurre squilibri.

- **Problema:** VM concentrate male possono saturare un host mentre altri restano quasi vuoti.
- **Soluzione:** monitorare workload e distribuire istanze sui server fisici più adatti.
- **Rischio:** migrazioni frequenti possono introdurre overhead se la policy non è stabile.

3.6 Load-Balanced Virtual Switches Architecture

I virtual server comunicano con l'esterno tramite virtual switch e uplink. Se tutto il traffico usa lo stesso uplink, si formano colli di bottiglia: ritardi, perdita di pacchetti, lag e degrado prestazionale. La load-balanced virtual switches architecture usa più uplink o percorsi ridondanti per bilanciare il traffico di rete.

- **Componenti:** virtual switch, uplink multipli, percorsi ridondanti, logica di bilanciamento.
- **Criticità:** deve evitare loop, squilibri di traffico e configurazioni incoerenti tra host.
- **Raccomandazione:** usarla quando il collo di bottiglia è la rete, non la CPU o la memoria.

3.7 Elastic Resource Capacity Architecture

Questa architettura riguarda il provisioning dinamico di CPU e RAM per virtual server. La scaling technology interagisce con hypervisor o VIM per prendere risorse dal pool e restituirle quando non servono.

Flusso operativo

1. Il carico della VM viene monitorato continuamente.
2. Prima che la soglia venga saturata, una policy richiede più CPU/RAM dal resource pool.
3. Hypervisor o VIM aumentano la capacità della VM.
4. Quando il carico cala, le risorse possono essere restituite al pool.

Differenza importante

- Elastic resource capacity = scaling verticale di CPU/RAM.
- Dynamic horizontal scaling = aggiunta di nuove istanze.
- Sono complementari, ma non equivalenti.

3.8 Cloud Bursting Architecture

La cloud bursting architecture permette a un sistema on-premises di “scoppiare” verso il cloud quando le soglie di capacità locali sono superate. Le risorse cloud ridondanti sono già predisposte ma restano inattive finché non serve capacità aggiuntiva.

```
On-premises Service A --carico normale--> risponde localmente
        |
        | soglia superata
        v
Automated Scaling Listener --> redirect richieste --> Cloud Service A
        |
        v
Resource Replication mantiene sincronizzato lo stato
```

- **Componenti:** servizio on-premises, cloud service ridondante, scaling listener, sincronizzazione stato, rete sicura.
- **Vantaggio:** si usa il cloud solo nei picchi, senza dimensionare il data center per il massimo carico.
- **Criticità:** latenza, consistenza dello stato, sicurezza del collegamento e costi di trasferimento dati.

3.9 Elastic Disk Provisioning Architecture

Questa architettura introduce il thin provisioning: il cloud consumer può vedere una capacità massima assegnata, ma il provider alloca realmente solo lo spazio effettivamente utilizzato. Il pay-per-use monitor misura l’uso reale per il billing.

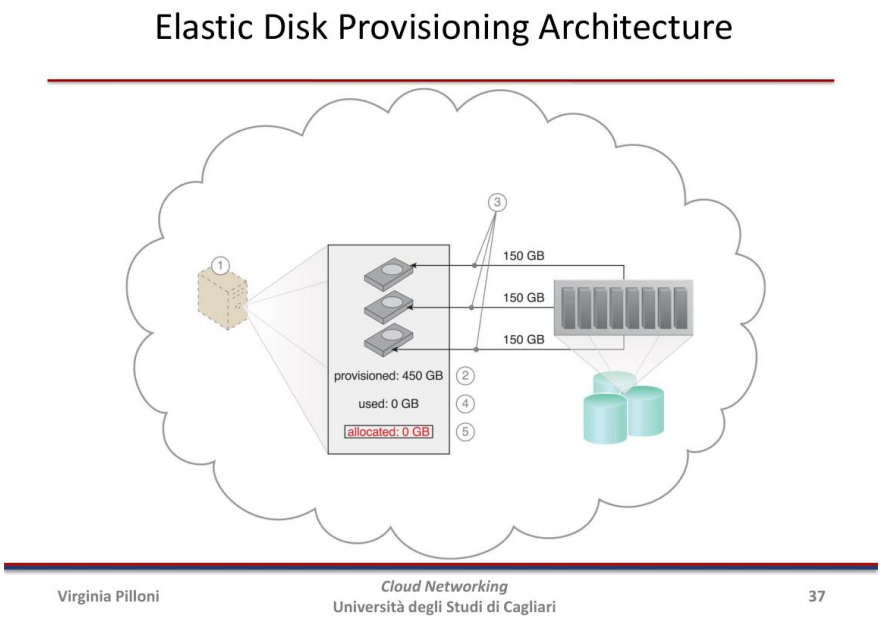


Figura - slide 37: allocazione logica elevata, ma spazio fisico inizialmente vicino a zero.

Concetto	Significato
Capacità dichiarata	Spazio massimo visibile alla VM o al consumer.
Capacità fisicamente usata	Spazio realmente allocato sullo storage provider.
Thin disk	Disco virtuale che cresce quando vengono scritti dati.
Pay-per-use monitor	Misura l'uso effettivo per fatturazione granulare.

Criticità

- Se molti consumer raggiungono contemporaneamente la capacità massima, il provider rischia overcommitment dello storage.
- Serve monitoraggio accurato della crescita reale e soglie di allarme.

3.10 Redundant Storage Architecture

La redundant storage architecture replica un dispositivo di storage primario su un dispositivo secondario. Un storage service gateway devia le richieste verso il secondario quando il primario fallisce.

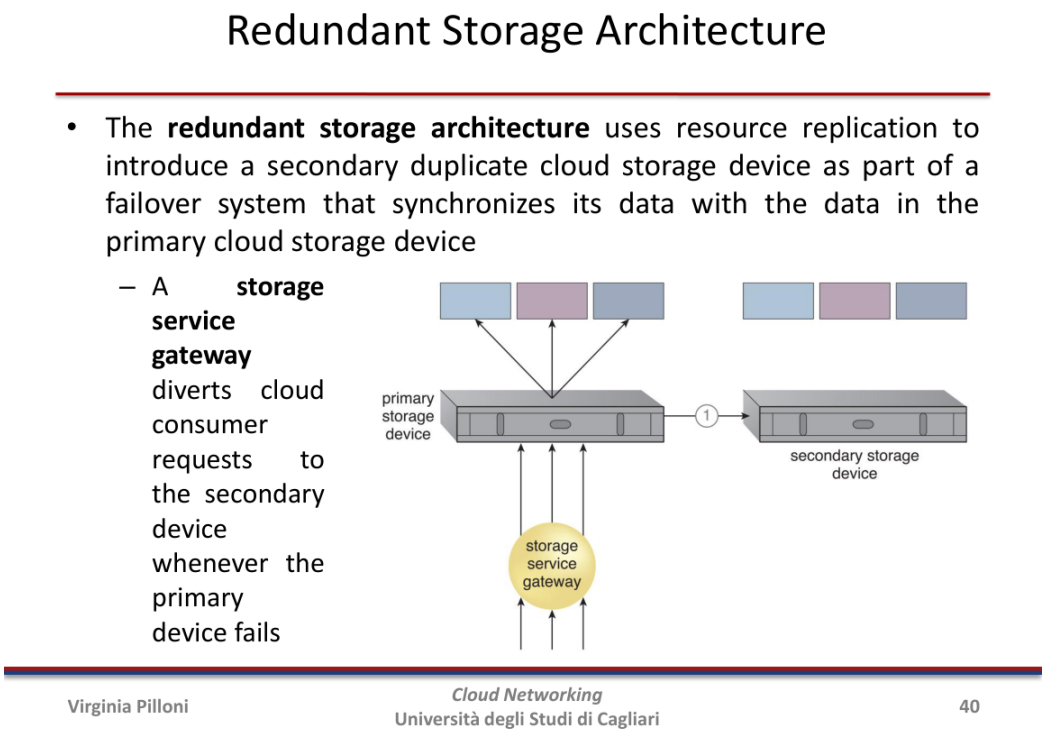


Figura - slide 40: storage primario, secondario e gateway di failover.

- **Componenti:** primary storage, secondary storage, resource replication, storage service gateway, LUN.
- **Flusso:** se il primario è disponibile, le richieste vanno al primario; se fallisce, il gateway passa al secondario.
- **Criticità:** sincronizzazione dati, RPO/RTO, latenza e coerenza.
- **Raccomandazione:** usare per workload in cui la perdita o indisponibilità dei dati è critica.

3.11 Multicloud Architecture

Una multicloud architecture combina due o più public cloud. Non significa solo "usare tanti servizi", ma distribuire architetture o componenti su cloud provider diversi.

Vantaggi	Svantaggi
Riduce lock-in verso un singolo provider.	Aumenta complessità di rete, sicurezza e governance.
Permette usare servizi migliori di provider diversi.	Richiede competenze multiple e strumenti di gestione coerenti.
Può migliorare resilienza cross-cloud.	Replica dati e consistenza diventano più difficili.

4. Advanced Cloud Architectures

Le architetture avanzate affrontano problemi più complessi: continuità operativa, failover, migrazione live, reservation, disaster recovery e provisioning automatico.

4.1 Hypervisor Clustering Architecture

Poiché un hypervisor può ospitare molte VM, il suo guasto può propagarsi a tutte le VM. L'hypervisor clustering crea un cluster HA di hypervisor su più server fisici, controllato da un VIM centrale.

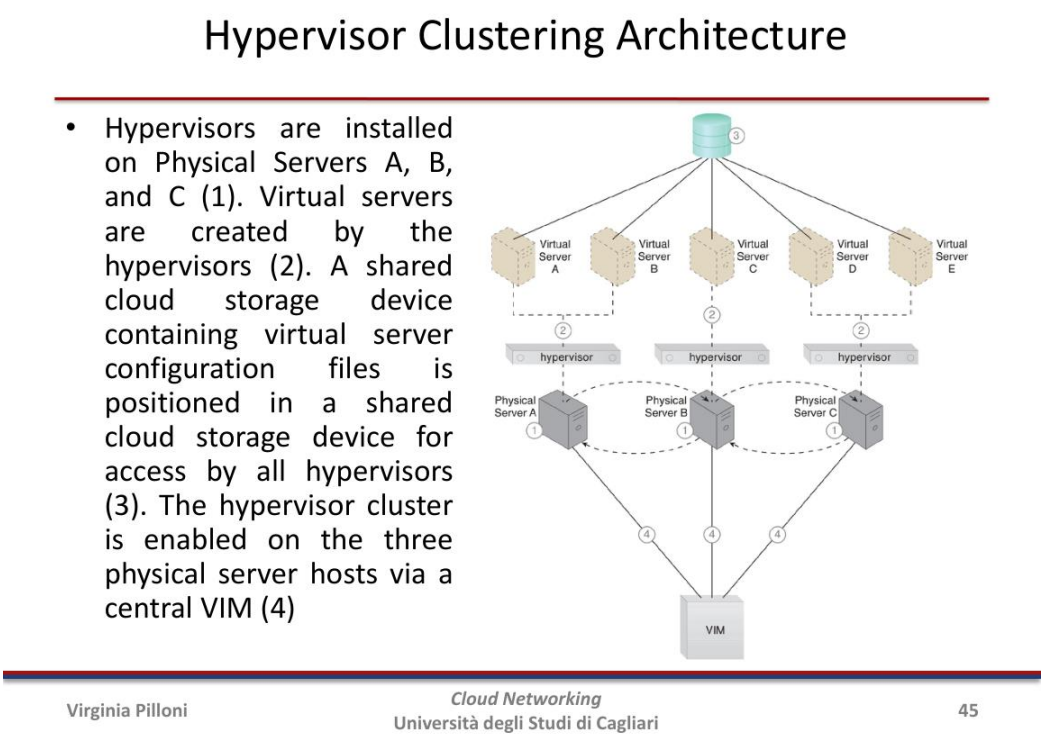


Figura - slide 45: cluster di hypervisor controllato dal VIM e storage condiviso.

Flusso di failover

1. Gli hypervisor girano su server fisici diversi e condividono configurazioni VM su storage condiviso.
2. Il VIM invia o riceve heartbeat periodici dagli hypervisor.
3. Se un server fisico non risponde, il VIM rileva il guasto.
4. Il VIM valuta la capacità residua degli altri host.
5. La VM impattata viene migrata o riavviata su un altro hypervisor.

Criticità e raccomandazioni

- Serve storage condiviso o replica coerente delle configurazioni VM.
- Heartbeat troppo lenti aumentano il tempo di rilevamento; troppo aggressivi possono generare falsi positivi.
- Il VIM deve essere ridondato o protetto, perché coordina il cluster.

4.2 Virtual Server Clustering Architecture

Questa architettura crea cluster di virtual server su host fisici diversi. È utile per workload distribuiti come big data analytics, SOA, database NoSQL distribuiti e piattaforme di container management.

- **Focus:** cluster di VM, non cluster di hypervisor.
- **Obiettivo:** scalabilità e resilienza del livello applicativo o di piattaforma.
- **Buona pratica:** distribuire le VM su host fisici diversi per evitare correlated failure.

4.3 Virtual Private Cloud Architecture

La virtual private cloud architecture realizza una private cloud su infrastruttura di un public cloud provider, dedicata a un cloud consumer specifico. Per il consumer appare come private cloud; per il provider resta parte della propria infrastruttura.

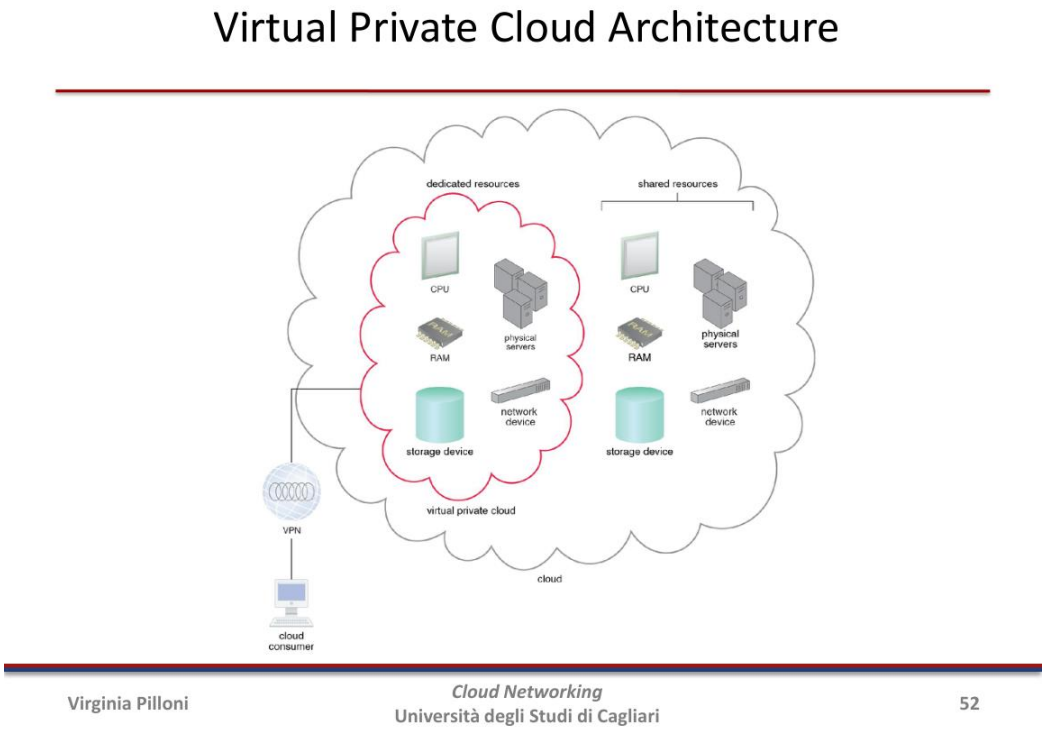


Figura - slide 52: isolamento dedicato e connessione sicura del consumer.

- **Uso:** organizzazioni che vogliono private cloud ma non hanno infrastruttura on-premises sufficiente.
- **Isolamento:** risorse fisiche non condivise con altri consumer e rete separata.
- **Connessione:** VPN sicura o collegamento fisico dedicato.
- **Criticità:** costi maggiori rispetto a VPC logica standard e minore elasticità rispetto a risorse completamente condivise.

4.4 Nondisruptive Service Relocation Architecture

Questa architettura consente di duplicare o migrare una cloud service implementation a runtime senza interrompere il servizio. Non si limita a fare scale-out: sposta l'attività verso un nuovo host e poi elimina la vecchia implementazione.

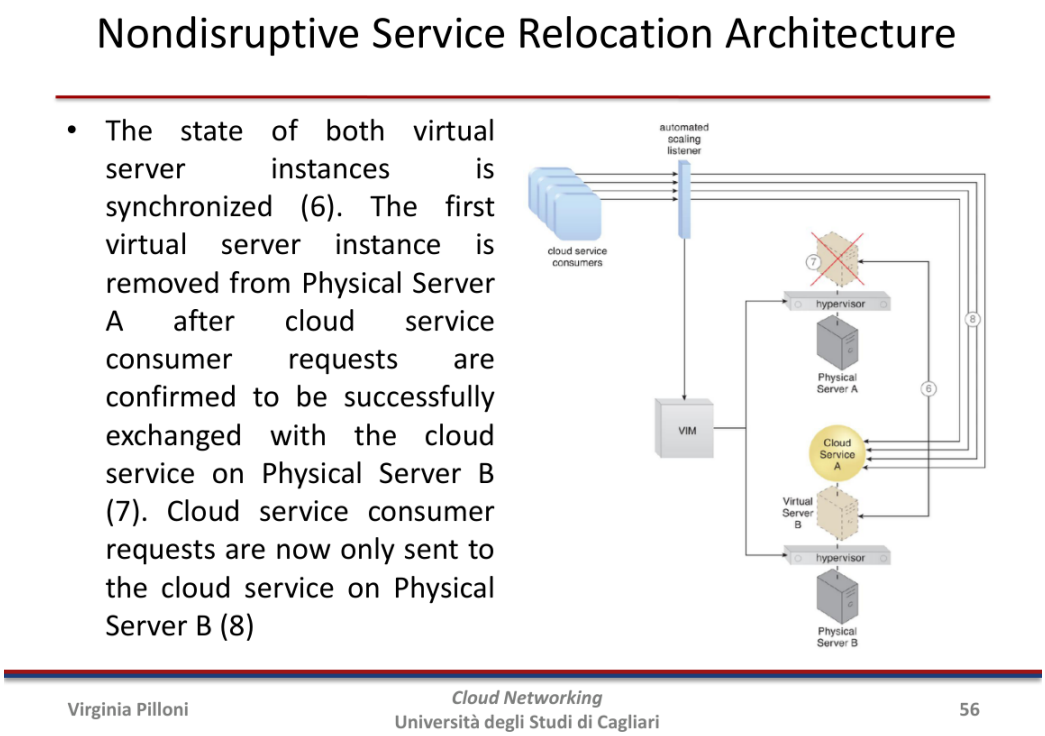


Figura - slide 56: sincronizzazione dello stato e rimozione della prima istanza dopo la migrazione.

Flusso operativo

1. Un automated scaling listener monitora il workload del servizio.
2. Una soglia o evento predefinito viene raggiunto.
3. Il listener segnala al VIM di iniziare la relocation.
4. Il VIM coordina gli hypervisor sorgente e destinazione.
5. Viene creata una seconda copia del virtual server sul nuovo host.
6. Lo stato viene sincronizzato.
7. Quando le richieste funzionano sul nuovo host, la vecchia istanza viene rimossa.

4.5 Zero Downtime Architecture

La zero downtime architecture è un failover sofisticato che sposta virtual server su host fisici diversi se l'host originale fallisce. Tutte le VM sono conservate su un volume condiviso, quindi possono essere riallocate senza interruzione percepibile o con interruzione minima.

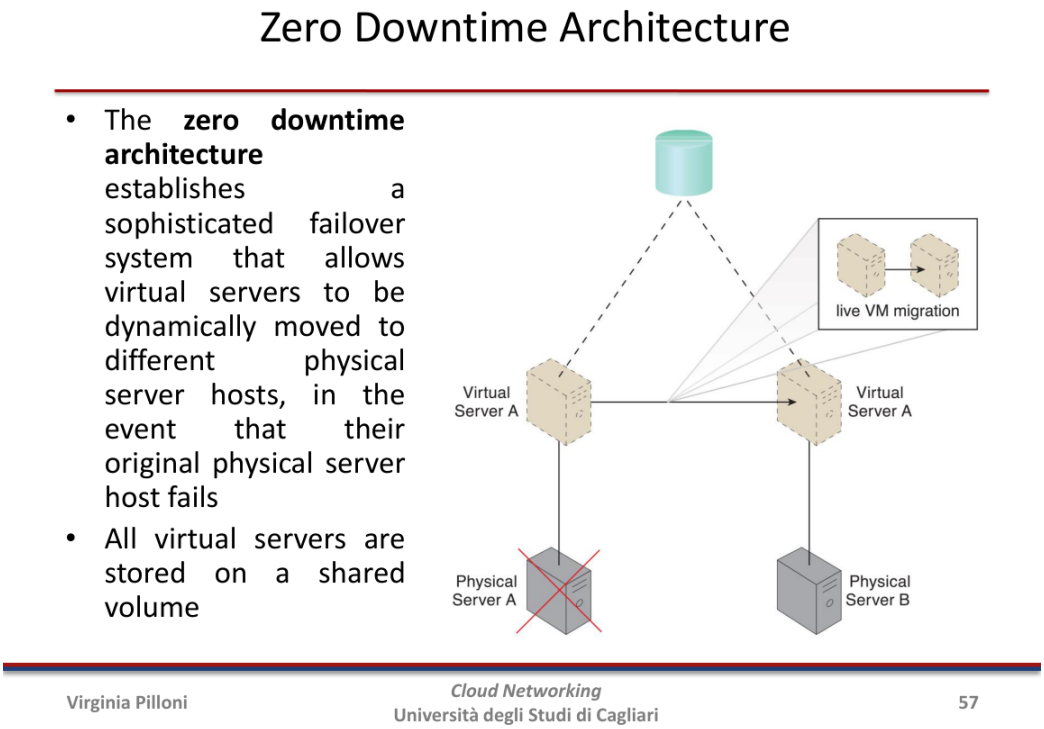


Figura - slide 57: failover dinamico con virtual server su volume condiviso.

Da esame

- Zero downtime non significa “non può mai succedere un guasto”. Significa progettare il sistema affinché il guasto di un host non interrompa il servizio percepito dal consumer.

4.6 Cloud Balancing Architecture

La cloud balancing architecture bilancia risorse IT su più cloud. Un automated scaling listener può reindirizzare richieste verso implementazioni ridondanti in cloud differenti; un failover system garantisce la continuità cross-cloud.

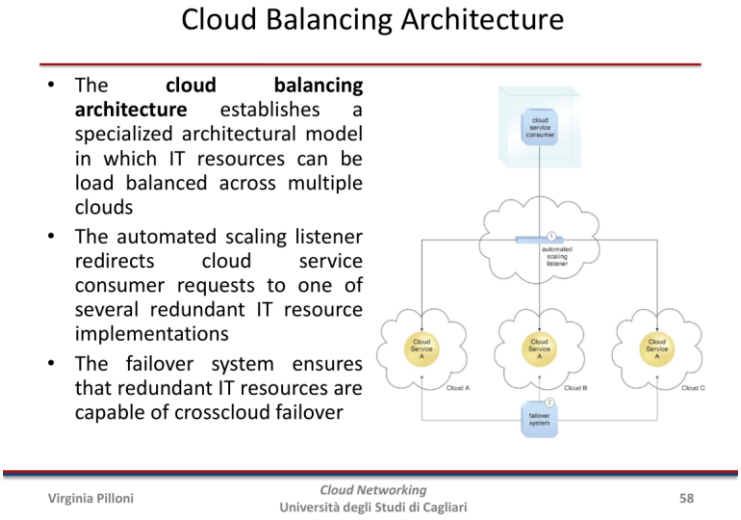


Figura - slide 58: bilanciamento e failover tra più cloud.

- **Pro:** resilienza geografica e indipendenza dal singolo provider.
- **Contro:** latenza, sincronizzazione dati, costi di uscita dati, sicurezza multi-provider.
- **Applicazione:** servizi globali con requisiti elevati di availability e disaster recovery.

4.7 Resilient Disaster Recovery Architecture

Questa architettura usa resource replication per creare copie ridondanti di tutte le risorse critiche in siti remoti. Le copie devono rimanere sincronizzate e pronte a sostituire gli originali in caso di disastro.

- **RPO:** quanto dato si può perdere al massimo.
- **RTO:** quanto tempo massimo si può restare indisponibili.
- **Meccanismo:** replica costante o periodica di servizi, dati e configurazioni.
- **Criticità:** test di failover, coerenza dati e costi di mantenimento delle risorse standby.

4.8 Resource Reservation Architecture

Questa architettura evita resource constraints quando più consumer condividono risorse con capacità limitata. Si creano pool parent e child con limiti definiti, così un consumer non può esaurire tutte le risorse danneggiando gli altri.

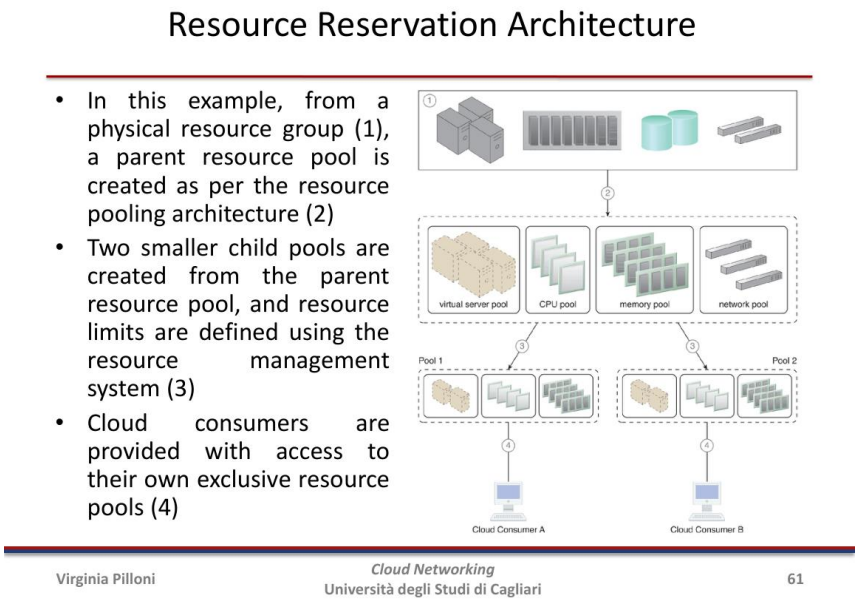


Figura - slide 61: creazione di child pool con limiti dedicati ai consumer.

- **Problema:** accesso concorrente a risorse insufficienti.
- **Soluzione:** limiti di pool e risorse riservate per ogni consumer o gruppo.
- **Trade-off:** maggiore garanzia di servizio, ma possibile riduzione dell'efficienza globale se le risorse riservate restano inutilizzate.

4.9 Dynamic Failure Detection and Recovery Architecture

Questa architettura usa un intelligent watchdog monitor per rilevare guasti e rispondere con azioni predefinite. Se il sistema non può risolvere automaticamente, notifica ed escala il problema.

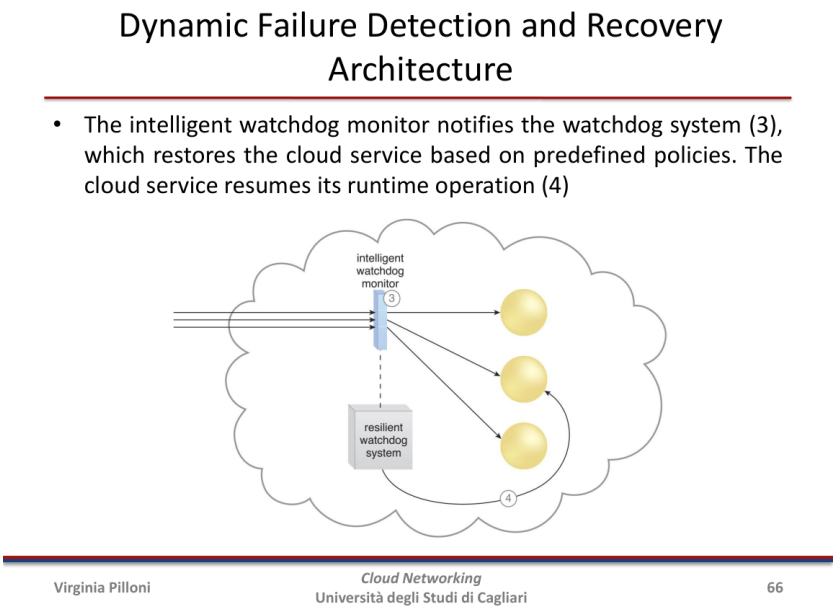


Figura - slide 66: watchdog monitor che notifica il sistema e ripristina il servizio.

Flusso di recovery

1. Il watchdog monitor osserva richieste e stato del servizio.
2. Rileva un fallimento o comportamento anomalo.
3. Notifica il watchdog system.
4. Il sistema applica policy di recovery: restart, replacement, failover o escalation.
5. Il servizio riprende l'operatività.

4.10 Rapid Provisioning Architecture

La rapid provisioning architecture automatizza la creazione di risorse IT o servizi cloud su richiesta. Usa un self-service portal, un automated service provisioning program, un rapid provisioning engine, script e template.

Flusso operativo

1. L'amministratore richiede un nuovo cloud service dal self-service portal.
2. Il portale passa la richiesta al provisioning program.
3. Il provisioning program invia task al rapid provisioning engine.
4. Il provisioning engine crea/configura le risorse e annuncia che il servizio è pronto.
5. Il provisioning program pubblica il servizio sul portale di uso e amministrazione.

4.11 Storage Workload Management Architecture

Questa architettura distribuisce LUN tra dispositivi di cloud storage per bilanciare i workload. Un sistema di storage capacity evita che alcune LUN o alcuni device ricevano troppo carico mentre altri restano sotto-utilizzati.

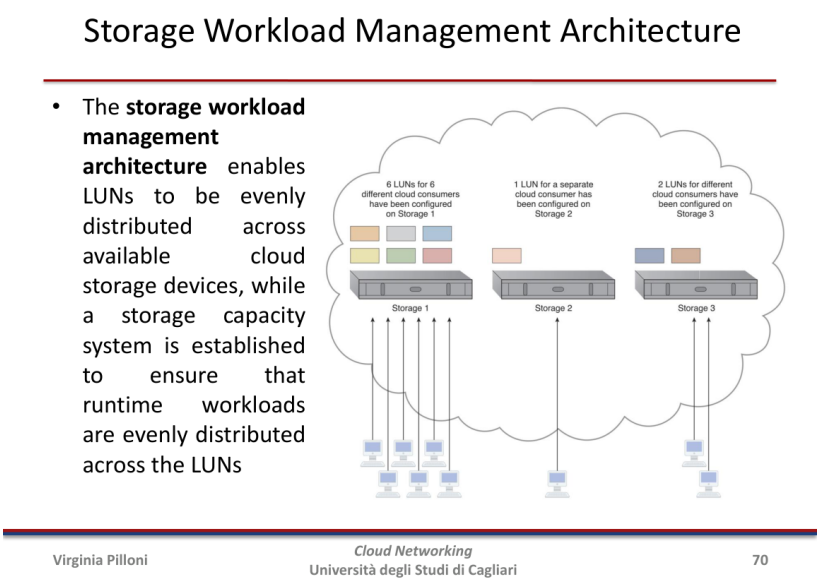


Figura - slide 70: LUN distribuite tra dispositivi di storage per bilanciare il carico.

5. Specialized Cloud Architectures

Le architetture specializzate risolvono problemi specifici di I/O, banda di rete, deduplicazione, tiering dello storage, multipath e persistenza della configurazione di rete.

5.1 Direct I/O Access Architecture

Con la direct I/O access architecture, una VM può bypassare l'hypervisor e accedere direttamente alla scheda I/O fisica. È utile quando la virtualizzazione della connettività tramite hypervisor o virtual switch diventa collo di bottiglia.

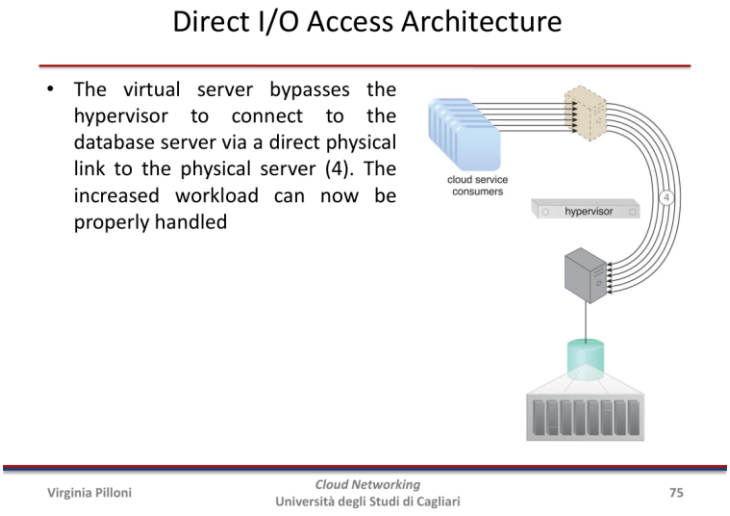


Figura - slide 75: bypass dell'hypervisor verso il database tramite link fisico diretto.

- **Pro:** migliora throughput e riduce overhead del percorso virtualizzato.
- **Contro:** riduce portabilità/migrazione della VM e richiede supporto hardware/driver.
- **Quando usarla:** workload I/O intensive dove il virtual switch limita le prestazioni.

5.2 Elastic Network Capacity Architecture

Questa architettura regola dinamicamente bandwidth, network ports o risorse di rete per evitare runtime bottlenecks. L'automated scaling listener monitora traffico e soglie; l'intelligent automation engine alloca più o meno capacità di rete.

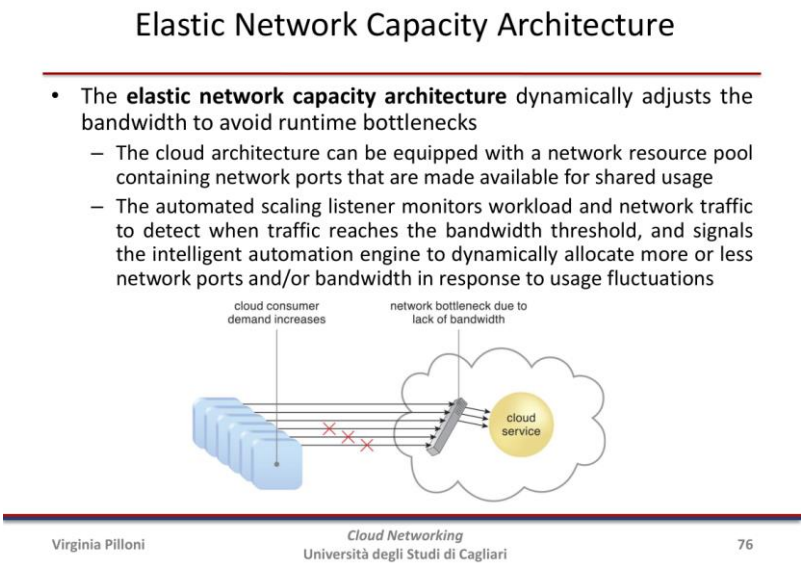


Figura - slide 76: allocazione dinamica di porte/banda tramite network resource pool.

- **Problema:** congestione di rete, jitter, ritardi, saturazione degli uplink.
- **Soluzione:** network resource pool e policy dinamiche di aggiunta/rilascio capacità.
- **Criticità:** coordinamento con routing, security policy e bilanciamento del traffico.

5.3 Dynamic Data Normalization Architecture

La dynamic data normalization architecture introduce deduplicazione: rileva blocchi o file ridondanti e li sostituisce con puntatori a copie già presenti. Riduce spazio, costi, backup e tempo di replica.

- **Vantaggi:** meno storage, meno backup, meno trasferimenti verso storage secondario.
- **Massima efficacia:** soprattutto su block storage, ma può essere applicata anche a file storage.
- **Rischio:** dipendenza da metadati/puntatori corretti; se corrotti, più dati possono diventare inaccessibili.

5.4 Cross-Storage Device Vertical Tiering Architecture

Questa architettura scala verticalmente lo storage spostando LUN tra dispositivi con capacità e prestazioni diverse. Quando le richieste superano una soglia, il sistema migra la LUN verso un device più performante senza disconnessioni.

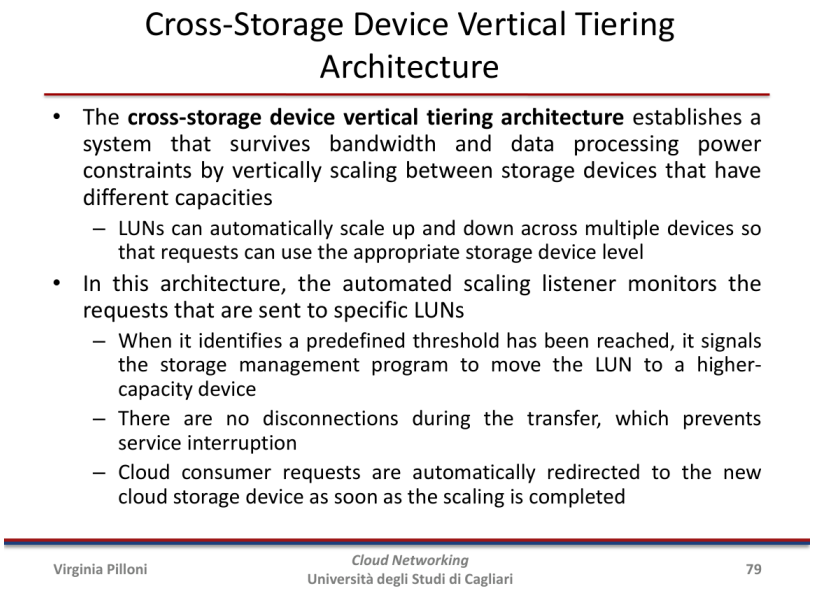


Figura - slide 79: spostamento verticale della LUN verso storage più capiente/performante.

Flusso di tiering cross-device

1. Le richieste arrivano al cloud storage device e alla LUN.
2. Il carico aumenta e raggiunge una soglia.
3. L'automated scaling listener notifica lo storage management program.
4. Il LUN migration program sposta la LUN su un dispositivo più performante.
5. Lo storage service gateway reindirizza le richieste alla nuova posizione.
6. Il sistema continua a monitorare se serve mantenere la LUN sul tier superiore.

5.5 Intra-Storage Device Vertical Data Tiering Architecture

Questa architettura è simile al tiering cross-device, ma resta dentro un singolo dispositivo di storage. Serve quando vincoli di sicurezza, privacy o legge impediscono di distribuire i dati su altri dispositivi.

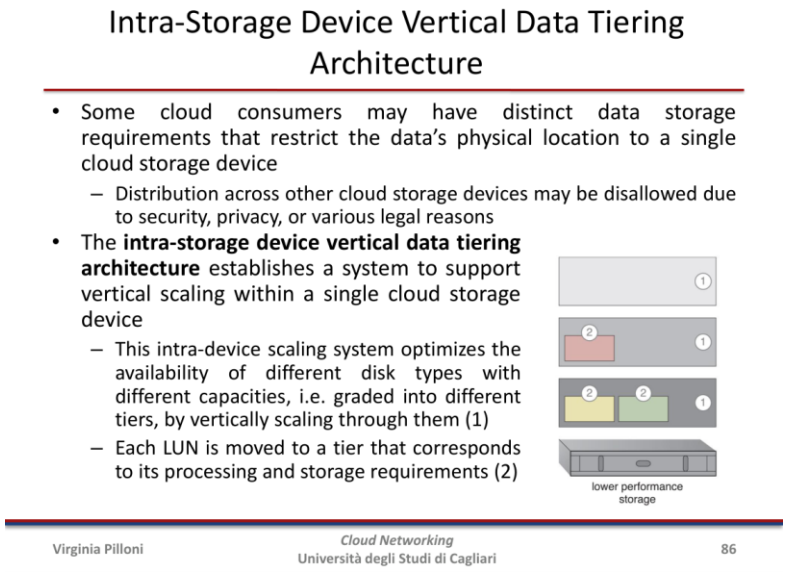


Figura - slide 86: tiering verticale dentro un singolo storage device.

- **Componenti:** disk group, tier, LUN migration, storage controller, usage monitor.
- **Vantaggio:** aumenta performance restando nello stesso dispositivo fisico/logico.
- **Contro:** richiede storage device complesso e può aumentare il costo quando la LUN passa a un tier più performante.

5.6 Multipath Resource Access Architecture

Alcune risorse sono accessibili tramite un unico path o hyperlink. Se quel path viene perso o cambia, la risorsa diventa indisponibile. La multipath resource access architecture crea percorsi fisici o virtuali alternativi verso la stessa risorsa.

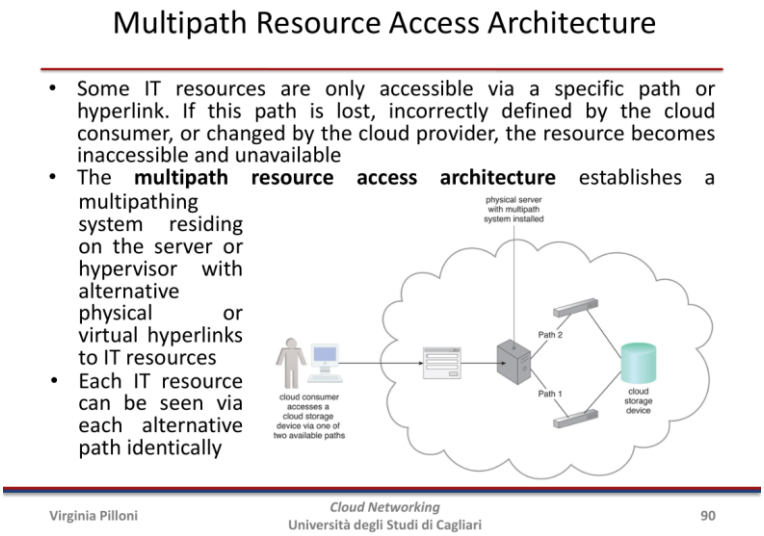


Figura - slide 90: percorsi alternativi verso la stessa risorsa IT.

- **Pro:** aumenta disponibilità e resilienza del path.
- **Contro:** richiede gestione coerente dei percorsi e prevenzione di configurazioni ambigue.
- **Uso tipico:** storage, collegamenti di rete critici, risorse con endpoint variabili.

5.7 Persistent Virtual Network Configuration Architecture

Quando una VM viene spostata su un nuovo host, può perdere configurazioni di rete e port assignment. Questa architettura centralizza la configurazione dei virtual switch nel VIM e la replica ai server fisici, così la connettività resta valida dopo la migrazione.

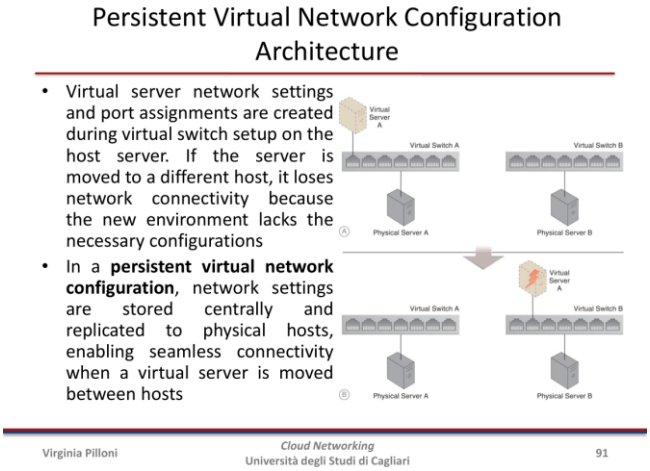


Figura - slide 91: configurazioni di rete replicate centralmente per mantenere connettività.

- **Problema:** migrazione VM senza configurazione di rete coerente sul nuovo host.
- **Soluzione:** virtual switch centralizzato e replica delle configurazioni.
- **Effetto:** mobilità delle VM senza perdita di connettività.

6. Edge, Fog, Metacloud e Federated Cloud Application

6.1 Edge Computing Architecture

L'edge computing introduce uno strato intermedio vicino al cloud consumer. I dati vengono processati alla periferia della rete, vicino alla sorgente. Il cloud conserva spesso le elaborazioni più pesanti.

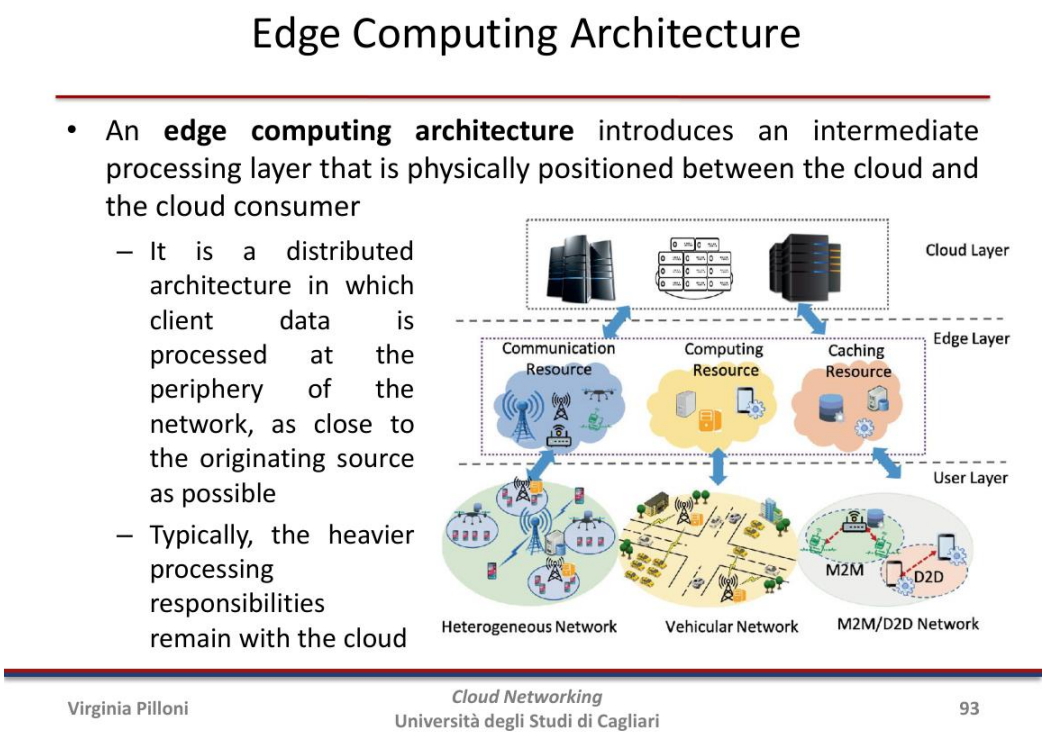


Figura - slide 93: processing alla periferia della rete vicino alla sorgente dati.

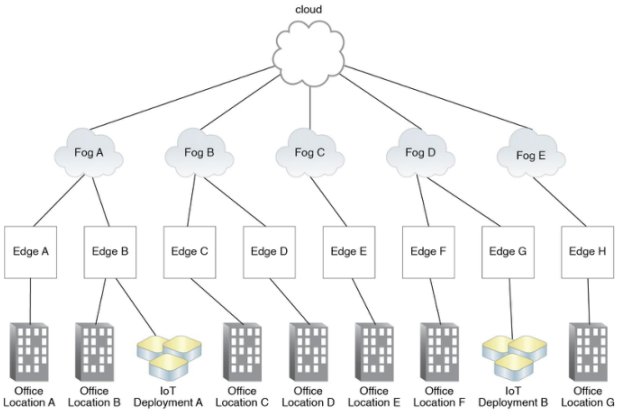
- **Riduzione latenza:** meno round-trip verso data center remoti.
- **Disponibilità:** distribuzione del processing su più dispositivi o piccoli data center.
- **Scalabilità:** si possono aggiungere dispositivi edge o edge data center più facilmente in scenari IoT.

6.2 Fog Computing Architecture

Il fog computing aggiunge uno strato tra edge e cloud. È utile in ambienti edge con molti dati: il fog layer filtra, prioritizza e aggrega, mandando al cloud solo ciò che è critico o utile centralmente.

Fog Computing Architecture

- A **fog computing architecture** adds an additional processing layer in between edge environments and a cloud
  - In data-heavy edge environments, the fog layer helps optimize transfers by prioritizing valuable data
  - Fog gateways send critical data to the cloud, while less important data is processed locally within the fog



Virginia Pilloni — *Cloud Networking* Università degli Studi di Cagliari — 95

Figura - slide 95: fog gateway tra edge environment e cloud.

Aspetto	Edge	Fog	Cloud
Posizione	Vicino alla sorgente dati.	Tra edge e cloud.	Data center remoto o regionale.
Ruolo	Processing locale rapido.	Filtro, aggregazione, prioritizzazione.	Elaborazione pesante e storage centrale.
Latenza	Minima.	Bassa/intermedia.	Più alta rispetto all'edge.
Uso tipico	IoT, sensori, controllo locale.	Gateway industriali, smart city.	Analytics globale, training, backup.

6.3 Metacloud Architecture

Il metacloud cerca di semplificare la complessità multicloud creando uno strato centralizzato e unificato di gestione. Idealmente questo layer va progettato prima di adottare il multicloud, non dopo, perché governance e sicurezza diventano più facili da standardizzare.

Metacloud Architecture

- Multicloud architectures offer flexibility by allowing the use of multiple cloud providers, but they also add complexity due to differing management and security requirements
- A **metacloud architecture** addresses this by creating a centralized, unified management layer, ideally implemented before adopting multicloud to streamline operations from the beginning

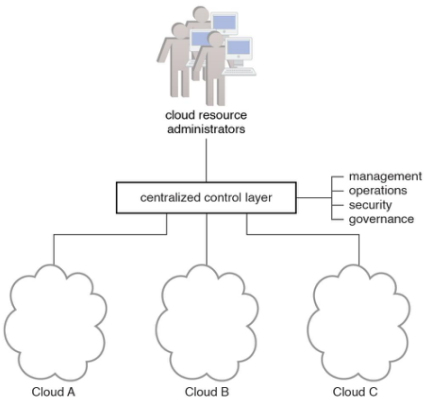


Figura - slide 96: management layer unificato sopra più cloud.

6.4 Federated Cloud Application Architecture

La federated cloud application architecture distribuisce componenti applicativi su più cloud per sfruttare i punti di forza di ciascun provider: prestazioni, resilienza, costo o servizi specifici. Migliora efficienza e performance, ma aumenta la complessità architetturale.

Federated Cloud Application Architecture

- Distributed cloud applications often run within a single cloud, limiting performance to that cloud's capabilities. A **federated cloud application architecture** overcomes this by deploying application components across multiple clouds, leveraging each one's strengths (e.g., performance, resiliency, cost)
  - While this enhances application performance and efficiency, it also increases architectural complexity

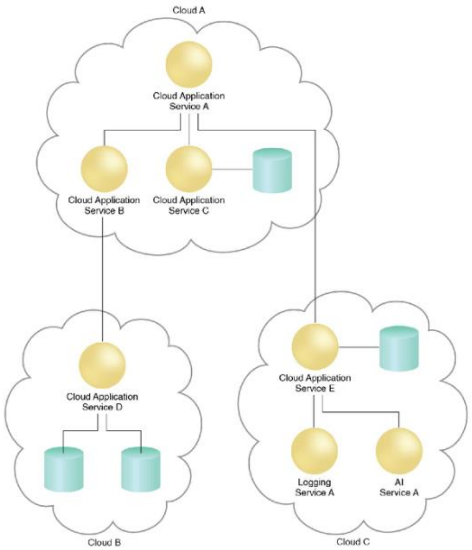


Figura - slide 97: componenti applicativi distribuiti su più cloud.

7. Tabelle di confronto e schemi da esame

7.1 Architetture per problema risolto

Problema	Architettura consigliata	Motivo
Carico applicativo variabile	Dynamic Scalability Architecture	Aggiunge/rimuove risorse in base a soglie e policy.
Distribuzione richieste tra istanze	Workload Distribution / Service Load Balancing	Usa load balancer e risorse equivalenti.
Guasto di hypervisor o host	Hypervisor Clustering / Zero Downtime	Migra o riavvia VM su host sani.
Picchi oltre capacità on-premises	Cloud Bursting	Usa risorse cloud inattive quando la soglia locale è superata.
Spreco di storage allocato	Elastic Disk Provisioning	Alloca fisicamente solo lo storage usato.
Guasto storage primario	Redundant Storage Architecture	Replica e failover verso storage secondario.
Congestione uplink o banda	Load-Balanced Virtual Switches / Elastic Network Capacity	Bilancia traffico o aggiunge capacità di rete.
Vincoli di latenza IoT	Edge/Fog Computing Architecture	Elabora dati vicino alla sorgente.

7.2 Vertical scaling vs horizontal scaling vs relocation

Tecnica	Cosa cambia	Esempio	Vantaggio	Limite
Horizontal scaling	Numero di istanze.	Aggiungo nuove VM o repliche.	Scala bene per servizi stateless.	Serve bilanciamento e gestione stato.
Vertical scaling	Capacità della singola risorsa.	Aumento CPU/RAM a una VM.	Semplice per workload non distribuiti.	Ha un limite fisico massimo.
Dynamic relocation	Posizione della risorsa.	Sposto VM su host più potente.	Riduce hotspot su host fisici.	Migrazione può introdurre overhead.

7.3 Schema rapido per esercizi progettuali

Quando l'esercizio chiede di progettare una nuova architettura cloud, puoi rispondere con questa struttura:

```
[Consumer / Utenti]
        |
[Logical Network Perimeter + Security Policy]
        |
[Load Balancer / Gateway]
        |
[Pool di risorse: VM, container, storage, rete]
        |
[Hypervisor Cluster + VIM]
        |
[Cloud Usage Monitor + Automated Scaling Listener]
        |
[Resource Replication / Failover / DR]
```

Frase pronta da esame

- La nuova architettura sostituisce risorse statiche e gestione manuale con pool di risorse monitorati, policy automatiche di scaling, bilanciamento del carico, replica e failover. In questo modo migliora scalabilità, disponibilità e resilienza rispetto allo scenario iniziale.

8. Esempio applicato: trasformazione di un data center tradizionale

Questo schema è utile per esercizi simili a uno scenario aziendale che passa da data center statico a cloud flessibile.

Scenario iniziale

```
[Utenti]
   |
[Logical Network Perimeter statico]
   |
[Router / Firewall manuale]
   |
[Server fisici isolati]
   |
[Singolo hypervisor / virtualizzazione limitata]
   |
[Storage fisso senza replica]
```

- Rischi: colli di bottiglia, scarsa scalabilità, failover assente, monitoraggio manuale.
- Limite principale: le risorse sono dimensionate staticamente e non seguono la domanda.

Scenario finale

```
[Utenti]
   |
[Logical Network Perimeter sicuro + VPN / policy]
   |
[Load Balancer + Virtual Switches bilanciati]
   |
[Cluster Hypervisor] <--> [VIM]
   |                         |
[Resource Pool: CPU/RAM/VM/Network/Storage]
   |
[Cloud Usage Monitor] --> [Automated Scaling Listener]
   |                         |
[Resource Replication] <-----+
   |
[Elastic Disk Provisioning + Redundant Storage + DR]
```

- Il VIM coordina hypervisor, migrazione live e allocazione delle risorse.
- Il load balancer distribuisce le richieste e riduce i colli di bottiglia.
- Il cloud usage monitor misura workload, stato e utilizzo effettivo.

- L’automated scaling listener attiva scale-out, scale-up o relocation.
- Lo storage elastico e ridondante evita sprechi e migliora disponibilità.

9. Domande d’esame con risposta

Domanda 1. Che cosa sono i cloud infrastructure mechanisms?

Risposta: Sono componenti fondamentali dell’ambiente cloud, come hypervisor, load balancer, usage monitor o resource replication, usati per costruire architetture cloud più complesse.

Domanda 2. Che cos’è un logical network perimeter?

Risposta: È un confine virtuale di rete che isola un gruppo di risorse cloud o on-premises dal resto della rete, controllando traffico e comunicazioni tramite firewall virtuali, reti virtuali o VPN.

Domanda 3. Qual è la differenza tra hypervisor e VIM?

Risposta: L’hypervisor crea e gestisce VM su un server fisico; il VIM coordina più hypervisor e consente gestione centralizzata, migrazione e amministrazione dell’infrastruttura virtuale.

Domanda 4. Quali sono i principali tipi di cloud storage device?

Risposta: File storage, block storage, dataset storage e object storage. Differiscono per unità logica, protocollo di accesso e casi d’uso.

Domanda 5. Che ruolo ha il cloud usage monitor?

Risposta: Raccoglie metriche di utilizzo e stato delle risorse. Queste metriche servono per billing, scaling automatico, health monitoring e recovery.

Domanda 6. Qual è la differenza tra monitoring agent, resource agent e polling agent?

Risposta: Il monitoring agent osserva dataflow; il resource agent rileva eventi della risorsa; il polling agent interroga periodicamente lo stato di risorse o servizi.

Domanda 7. Perché la resource replication è importante?

Risposta: Perché consente di creare copie di risorse IT per scaling, alta disponibilità e disaster recovery.

Domanda 8. Che cos’è una resource pooling architecture?

Risposta: È un’architettura in cui risorse IT omogenee sono raggruppate in pool sincronizzati da cui il cloud può allocare capacità dinamicamente.

Domanda 9. Che differenza c’è tra scaling orizzontale e verticale?

Risposta: Lo scaling orizzontale aggiunge nuove istanze; lo scaling verticale aumenta la capacità di una singola istanza, ad esempio CPU o RAM.

Domanda 10. Che cosa fa l’automated scaling listener?

Risposta: Monitora workload e soglie; quando una policy viene soddisfatta, attiva un’azione di scaling, relocation o provisioning.

Domanda 11. Quando si usa la workload distribution architecture?

Risposta: Quando si vuole distribuire traffico o carico su più risorse identiche tramite load balancer, riducendo sovraccarico e sprechi.

Domanda 12. Che cosa distingue la service load balancing architecture?

Risposta: È focalizzata sul bilanciamento di implementazioni duplicate di cloud service organizzate in un resource pool.

Domanda 13. Qual è il problema risolto dalla load-balanced virtual switches architecture?

Risposta: Risolve colli di bottiglia sugli uplink dei virtual switch distribuendo il traffico su più uplink o percorsi ridondanti.

Domanda 14. Che cos'è l'elastic resource capacity architecture?

Risposta: È un modello che alloca e rilascia dinamicamente CPU e RAM alle VM in base al carico, usando pool di risorse e hypervisor/VIM.

Domanda 15. Che cos'è il cloud bursting?

Risposta: È un modello in cui un ambiente on-premises usa risorse cloud aggiuntive quando supera soglie di capacità, poi rientra nel data center quando il picco termina.

Domanda 16. Qual è il vantaggio dell'elastic disk provisioning?

Risposta: Evita di pagare o allocare fisicamente tutto lo spazio dichiarato: tramite thin provisioning lo storage cresce in base all'uso reale.

Domanda 17. Che ruolo ha lo storage service gateway nella redundant storage architecture?

Risposta: Indirizza le richieste verso lo storage primario o, in caso di guasto, verso lo storage secondario replicato.

Domanda 18. Che cos'è una multicloud architecture?

Risposta: È un'architettura che combina due o più public cloud provider per flessibilità, resilienza o uso di servizi specifici.

Domanda 19. Come funziona l'hypervisor clustering architecture?

Risposta: Più hypervisor su server fisici diversi sono coordinati da un VIM. Heartbeat e live migration permettono di spostare VM in caso di guasto.

Domanda 20. Che differenza c'è tra hypervisor clustering e virtual server clustering?

Risposta: Hypervisor clustering protegge e coordina il livello hypervisor/host; virtual server clustering organizza più VM in cluster applicativi o infrastrutturali.

Domanda 21. Che cos'è la nondisruptive service relocation architecture?

Risposta: È un modello che sposta o duplica un servizio a runtime verso un nuovo host, sincronizzando lo stato e rimuovendo la vecchia istanza solo dopo conferma operativa.

Domanda 22. Che cos'è la zero downtime architecture?

Risposta: È un sistema di failover in cui le VM possono essere spostate dinamicamente su altri host se l'host originale fallisce, riducendo o eliminando l'interruzione del servizio.

Domanda 23. A cosa serve la resource reservation architecture?

Risposta: Serve a evitare resource constraints tra consumer concorrenti definendo pool, limiti e quote riservate.

Domanda 24. Che cosa fa la dynamic failure detection and recovery architecture?

Risposta: Usa un intelligent watchdog monitor per rilevare guasti e applicare automaticamente policy di recovery o escalation.

Domanda 25. Che cos'è la rapid provisioning architecture?

Risposta: È un'architettura che automatizza la creazione e pubblicazione di servizi cloud tramite self-service portal, provisioning program, engine, script e template.

Domanda 26. Quando conviene la direct I/O access architecture?

Risposta: Quando il percorso virtualizzato tramite hypervisor o virtual switch limita le prestazioni I/O e serve accesso diretto alla scheda fisica.

Domanda 27. Quale problema risolve l'elastic network capacity architecture?

Risposta: Risolve bottleneck di rete allocando dinamicamente porte, banda o risorse di rete in base al traffico monitorato.

Domanda 28. Che cos'è la dynamic data normalization architecture?

Risposta: È un modello di deduplicazione che elimina dati ridondanti sostituendoli con puntatori a blocchi o contenuti già memorizzati.

Domanda 29. Differenza tra cross-storage vertical tiering e intra-storage vertical tiering?

Risposta: Il cross-storage sposta LUN tra dispositivi storage diversi; l'intra-storage sposta LUN tra tier diversi dentro lo stesso dispositivo.

Domanda 30. Che cosa fa la persistent virtual network configuration architecture?

Risposta: Centralizza e replica configurazioni di rete virtuale su host fisici, così una VM mantiene connettività anche dopo migrazione.

Domanda 31. Differenza tra edge e fog computing?

Risposta: L'edge processa vicino alla sorgente dati; il fog aggiunge uno strato intermedio tra edge e cloud per filtrare, aggregare e prioritizzare i dati.

Domanda 32. Che cos'è una metacloud architecture?

Risposta: È uno strato centralizzato e unificato di gestione pensato per semplificare ambienti multicloud complessi.

Domanda 33. Che cos'è una federated cloud application architecture?

Risposta: È un modello in cui componenti applicativi sono distribuiti su più cloud per sfruttare i punti di forza di provider diversi, aumentando però la complessità.

10. Ripasso finale ultra-rapido

Se leggi...	Pensa subito a...
Soglia superata	Automated scaling listener + policy.
Più istanze identiche	Horizontal scaling + load balancer.
Più CPU/RAM su una VM	Vertical scaling / elastic resource capacity.
Guasto host/hypervisor	Hypervisor clustering, zero downtime, live migration.
Storage pagato solo se usato	Elastic disk provisioning / thin provisioning.
Storage primario guasto	Redundant storage + gateway + replica.
Troppo traffico su uplink	Load-balanced virtual switches o elastic network capacity.
Picco oltre data center locale	Cloud bursting.
Molti cloud provider	Multicloud, metacloud, cloud balancing o federated cloud application.

Bassa latenza vicino ai dispositivi	Edge/fog computing.